

ĐỒ ÁN CƠ SỞ

ỨNG DỤNG K-MEANS VÀ RFM: CHIẾN LƯỢC PHÂN KHÚC KHÁCH HÀNG HIỆU QUẢ

Ngành: **KHOA HỌC DỮ LIỆU**

Chuyên ngành: **KHOA HỌC DỮ LIỆU**

Giảng viên hướng dẫn: **ThS.NGUYỄN QUANG PHÚC**

Nhóm sinh viên thực hiện:

Nguyễn Nhật Nam MSSV: 2286400019

Hoàng Quang Minh MSSV: 2286400017

Hà Thế Anh MSSV: 2286400002

Lớp: 22DKHA1

TP. Hồ Chí Minh, 2025

ĐỒ ÁN CƠ SỞ

ỨNG DỤNG K-MEANS VÀ RFM: CHIẾN LƯỢC PHÂN KHÚC KHÁCH HÀNG HIỆU QUẢ

Ngành: **KHOA HỌC DỮ LIỆU**

Chuyên ngành: **KHOA HỌC DỮ LIỆU**

Giảng viên hướng dẫn: **ThS.NGUYỄN QUANG PHÚC**

Sinh viên thực hiện:

Nguyễn Nhật Nam MSSV: 2286400019

Hoàng Quang Minh MSSV: 2286400017

Hà Thế Anh MSSV: 2286400002

Lớp: 22DKHA1

TP. Hồ Chí Minh, 2025

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TP.HCM, Ngày... tháng... năm 2025

Giảng viên hướng dẫn

(Ký tên, đóng dấu)

Mục lục

CHƯƠNG 1: TỔNG QUAN	8
1.1. Giới thiệu đề tài	8
1.2. Nhiệm vụ của đề tài	8
1.2.1. Tính cấp thiết của đề tài	8
1.2.2. Ý nghĩa khoa học và thực tiễn của đề tài	8
1.3. Mục tiêu nghiên cứu	8
1.3.1. Mục tiêu tổng quát	8
1.3.2. Mục tiêu cụ thể	9
1.4. Đối tượng và phạm vi nghiên cứu	9
1.4.1. Đối tượng nghiên cứu	9
1.4.2. Phạm vi nghiên cứu	9
1.5. Phương pháp nghiên cứu	9
1.5.1. Phương pháp nghiên cứu sơ bộ	9
1.5.2. Phương pháp nghiên cứu tài liệu	9
1.5.3. Phương pháp nghiên cứu thống kê	10
1.5.4. Phương pháp thực nghiệm	10
1.5.5. Phương pháp đánh giá	10
1.6. Đóng góp của đề tài	10
1.6.1. Trong lĩnh vực học thuật	10
1.6.2. Trong thực tiễn kinh doanh	10
CHƯƠNG 2: TỔNG QUAN LÝ THUYẾT	11
2.1 Phân tích hành vi khách hàng và tầm quan trọng của phân khúc	11
2.1.1 Các hình thức phân khúc khách hàng	12
2.2. Mô hình RFM	12
2.2.1 Ưu điểm của RFM	13
2.3. Chuẩn hóa dữ liệu (Standardization)	14
2.3.1. Cơ sở toán học của chuẩn hóa	14
2.3.2. Lợi ích khi áp dụng chuẩn hóa	14
2.3.3. Hạn chế và điểm cần lưu ý	15
2.3.4. Vai trò trong các thuật toán học máy	15
2.4. Ngoại lệ trong dữ liệu và vai trò trong phân tích	15
2.4.1. Khái niệm ngoại lệ (Outlier)	15
2.4.2. Tác động của ngoại lệ đến phân tích và mô hình học máy	15

2.4.3. Phương pháp phát hiện ngoại lệ	16
2.4.4. Ưu điểm và nhược điểm của việc xử lý ngoại lệ	16
2.4.5. Vai trò của xử lý ngoại lệ trong quá trình phân tích	17
2.5. Thuật toán phân cụm K – Means	17
2.5.1. Khái niệm về K – Means	17
2.5.2. Cách hoạt động của K-Means	18
2.5.3. Lựa chọn số cụm K trong K-Means	19
2.5.4. Ưu điểm và nhược điểm của K-Means	20
2.5.5. Ứng dụng của K-Means trong thực tế	20
2.5.6. Giả định của thuật toán K-Means	21
2.5.7. K-Means trong phân khúc khách hàng dựa trên mô hình RFM	21
2.6. Các phương pháp chọn số cụm tối ưu	21
2.6.1. Phương pháp Elbow (Khủy tay)	22
2.6.2. Phương pháp Silhouette	23
2.6.3. Phương pháp Calinski–Harabasz (CH Index)	24
2.6.4. Chỉ số Davies–Bouldin (DBI)	26
2.7. Kỹ thuật giảm chiều để trực quan hóa	27
2.7.1. PCA (Principal Component Analysis).	27
2.7.2. t-SNE (t-distributed Stochastic Neighbor Embedding).	28
2.7.3. UMAP (Uniform Manifold Approximation and Projection).	30
CHƯƠNG 3: PHƯƠNG PHÁP THỰC NGHIỆM	31
3.1. Quá trình thực nghiệm	31
3.1.1. Mục tiêu của quá trình thực nghiệm	31
3.1.2. Sơ đồ quy trình	31
3.2. Giới thiệu tập dữ liệu	31
3.2.1. Nguồn gốc và bối cảnh dữ liệu	31
3.2.2. Mô tả cấu trúc và các thuộc tính chính	32
3.2.3. Ý nghĩa các biến trong phân tích hành vi khách hàng	32
3.3. Khám phá dữ liệu	32
3.3.1. Thống kê mô tả tổng quan tập dữ liệu	32
3.3.2. Kiểm tra giá trị thiếu và kiểu dữ liệu	33
3.3.3. Phát hiện các giá trị bất thường (Quantity, UnitPrice)	33
3.3.4. Số lượng khách hàng và thời gian giao dịch	33
3.3.5. Phát hiện mã bất thường trong InvoiceNo và StockCode	34
3.4. Làm sạch và xử lý dữ liệu	34

3.4.1. Loại bỏ các giao dịch không hợp lệ	34
3.4.2. Xử lý dữ liệu thiếu và chuyển đổi kiểu dữ liệu	35
3.4.4. Đánh giá dữ liệu sau làm sạch	36
3.4.5. Trực quan hóa mối quan hệ <i>Quantity – UnitPrice</i> (Heatmap)	37
3.5. Chuẩn bị dữ liệu RFM cho phân tích phân cụm	37
3.5.1. Tạo biến <i>SalesLineTotal</i> cho từng giao dịch	38
3.5.2. Tính các chỉ số RFM theo khách hàng	38
3.5.3. Phân tích phân phối và kiểm tra bất thường trong RFM	38
3.5.4. Xử lý outliers trong RFM	40
3.5.5. Đánh giá dữ liệu RFM sau xử lý	41
3.6. Chuẩn hóa dữ liệu	43
3.6.1. Mục tiêu và lý do chuẩn hóa	43
3.6.2. Chuẩn hóa bằng Z-score (<i>StandardScaler</i>)	43
3.6.3. Trực quan hóa ma trận tương quan sau chuẩn hóa (Heatmap)	43
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM	46
4.1. Phân cụm dữ liệu	46
4.1.1. Chọn số lượng cụm tối ưu (<i>k</i>) trong phân cụm <i>K-Means</i>	46
4.1.2. Huấn luyện mô hình phân cụm bằng <i>K-Means</i>	47
4.2. Phân tích kết quả	48
4.2.1. Trực quan hóa và phân tích kết quả phân cụm	48
4.2.2. Phân cụm bằng <i>t-SNE</i>	50
4.2.3. Trực quan biểu đồ phân cụm sau khi giảm chiều bằng <i>UMAP</i>	51
4.2.4. Trực quan kết quả phân cụm các nhóm khách hàng bằng biểu đồ <i>Violin</i>	52
4.2.5. Phân loại các nhóm ngoại lai theo 2 chỉ số (<i>Monetary</i>) và (<i>Frequency</i>)	54
4.2.6. Trực quan kết quả phân cụm các nhóm khách hàng ngoại lai	54
4.3. Đề xuất chiến lược phù hợp cho các nhóm khách hàng	56
4.3.1. Đề xuất chiến lược cho các nhóm chính	56
4.3.2. Đề xuất chiến lược cho các nhóm ngoại lai	57
4.4. Gán nhãn và trình bày kết quả phân cụm khách hàng	58
4.4.1 Tiến hành gán nhãn chiến lược cho các cụm	58
4.4.2 Tạo bảng dữ liệu phân cụm đầy đủ	58
4.4.3 Ánh xạ tên chiến lược cho từng cụm khách hàng	58
4.4.4 Trực quan hóa phân bố khách hàng và giá trị trung bình theo cụm	58

CHƯƠNG 5: KẾT LUẬN VÀ KIẾN NGHỊ	60
5.1. Kết luận	60
5.2. Kiến nghị	60
TÀI LIỆU THAM KHẢO	61

LỜI CAM ĐOAN

Chúng tôi, Hoàng Quang Minh, Nguyễn Nhật Nam và Hà Thế Anh xin cam đoan rằng:

Mọi thông tin và nghiên cứu được trình bày trong bài báo cáo này là trung thực và khách quan được thu thập và phân tích một cách cẩn thận dựa trên các nguồn chính thống và đáng tin cậy.

Bất kỳ thông tin hoặc ý kiến nào được trích dẫn từ các nguồn khác đều được nêu rõ nguồn gốc và được trích dẫn theo đúng quy định. Chúng tôi xin cam đoan rằng không có bất kỳ sự sao chép hoặc sử dụng thông tin không đúng dẫn nào từ các nguồn khác.

Bài báo cáo này là công trình nghiên cứu độc lập của chúng tôi chưa từng được công bố ở bất kỳ nơi nào khác. Tôi cam đoan rằng đã tuân thủ đầy đủ các quy tắc và quy định của môn học bao gồm cả việc tham khảo và sử dụng công cụ nghiên cứu.

Tôi hy vọng rằng bài báo cáo này sẽ cung cấp một cái nhìn tổng quan rõ ràng và toàn diện về chủ đề “Ứng dụng K-Means và RFM: Chiến lược phân khúc khách hàng hiệu quả” và sẽ đóng góp một phần nhỏ vào lĩnh vực nghiên cứu này.

TP. Hồ Chí Minh, ngày 15 tháng 4 năm 2025

Sinh viên

Hoàng Quang Minh
Nguyễn Nhật Nam
Hà Thế Anh

DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT VÀ TỪ KHÓA

1. Ký hiệu và chữ viết tắt

- **RFM**: Recency – Frequency – Monetary (Thời gian gần nhất - Tần suất - Giá trị chi tiêu)
- **K-Means**: Thuật toán phân cụm K-Means
- **PCA**: Principal Component Analysis - Phân tích thành phần chính
- **t-SNE**: t-distributed Stochastic Neighbor Embedding - Phép nhúng lân cận xác suất
- **UMAP**: Uniform Manifold Approximation and Projection - Xấp xỉ và chiếu theo đa tạp
- **WCSS**: Within-Cluster Sum of Squares - Tổng phương sai trong cụm
- **CH Index**: Calinski-Harabasz Index - Chỉ số đánh giá cụm
- **DBI**: Davies-Bouldin Index - Chỉ số phân tách cụm

2. Từ khóa

- Phân khúc khách hàng
- Mô hình RFM
- Thuật toán K-Means
- Hành vi người tiêu dùng
- Chuẩn hóa dữ liệu
- Xử lý ngoại lệ
- Giảm chiều dữ liệu
- Trực quan hóa phân cụm
- Chiến lược marketing theo nhóm
- Dữ liệu lịch sử giao dịch
- Phân tích dữ liệu khách hàng

CHƯƠNG 1: TỔNG QUAN

1.1. Giới thiệu đề tài

Trong bối cảnh chuyển đổi số, dữ liệu khách hàng ngày càng trở thành tài sản chiến lược của doanh nghiệp. Với việc khai thác hiệu quả dữ liệu để thấu hiểu hành vi tiêu dùng vẫn là một thách thức. Phân khúc khách hàng tức chia nhóm khách hàng theo đặc điểm hành vi tương đồng đóng vai trò quan trọng trong tối ưu hóa marketing, sử dụng nguồn lực hiệu quả và nâng cao trải nghiệm khách hàng.

Một cách tiếp cận hiệu quả là kết hợp mô hình RFM với thuật toán K-Means. RFM giúp định lượng hành vi theo ba chiều: thời gian mua hàng gần nhất (Recency), tần suất (Frequency), và giá trị giao dịch (Monetary). Khi áp dụng K-Means – một thuật toán học không giám sát phổ biến – quá trình phân nhóm trở nên nhanh chóng, trực quan và giàu giá trị thực tiễn.

Từ nhu cầu đó, đề tài “Ứng dụng K-Means và RFM: Chiến lược phân khúc khách hàng hiệu quả” được thực hiện nhằm xây dựng một quy trình phân tích rõ ràng, có tính ứng dụng cao trong lĩnh vực thương mại điện tử và bán lẻ.

1.2. Nhiệm vụ của đề tài

1.2.1. Tính cấp thiết của đề tài

Thực tế cho thấy, dù nắm trong tay lượng dữ liệu lớn, nhiều doanh nghiệp vẫn chưa tận dụng được sức mạnh của dữ liệu để triển khai các chiến lược tiếp cận khách hàng hiệu quả. Các chiến dịch tiếp thị vẫn còn mang tính đại trà, thiếu cá nhân hóa, dẫn đến chi phí cao và hiệu quả thấp. Việc áp dụng mô hình phân tích hành vi khách hàng một cách định lượng là bước đi cần thiết để tối ưu hóa hoạt động marketing, đặc biệt trong bối cảnh xu hướng “data-driven” ngày càng phát triển.

1.2.2. Ý nghĩa khoa học và thực tiễn của đề tài

Về mặt học thuật, đề tài góp phần làm rõ ứng dụng của mô hình RFM và thuật toán K-Means trong khai thác hành vi khách hàng thông qua dữ liệu giao dịch. Về mặt thực tiễn, nghiên cứu này mang lại một quy trình rõ ràng, có thể triển khai trực tiếp trong doanh nghiệp nhằm phục vụ các mục tiêu như phân khúc khách hàng, cá nhân hóa trải nghiệm và tối ưu hóa nguồn lực tiếp thị.

1.3. Mục tiêu nghiên cứu

1.3.1. Mục tiêu tổng quát

Xây dựng một mô hình phân khúc khách hàng ứng dụng mô hình RFM và thuật toán K-Means, từ đó đề xuất các chiến lược tiếp cận phù hợp với từng nhóm khách hàng nhằm nâng cao hiệu quả kinh doanh.

1.3.2. Mục tiêu cụ thể

Đề tài tập trung vào việc tính toán và chuẩn hóa các chỉ số RFM từ dữ liệu giao dịch thực tế, áp dụng thuật toán K-Means để phân chia khách hàng thành các cụm hành vi tương đồng, đồng thời sử dụng các chỉ số như **Silhouette Score**, **Calinski-Harabasz Index** và **Davies-Bouldin Index** để đánh giá chất lượng phân cụm. Trên cơ sở kết quả thu được, nghiên cứu đề xuất chiến lược tiếp cận cụ thể cho từng phân khúc khách hàng nhằm hỗ trợ doanh nghiệp trong công tác tiếp thị và chăm sóc khách hàng một cách tối ưu.

1.4. Đối tượng và phạm vi nghiên cứu

1.4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu là dữ liệu giao dịch khách hàng, bao gồm thông tin về thời gian, tần suất và giá trị đơn hàng - ba yếu tố cấu thành mô hình RFM.

1.4.2. Phạm vi nghiên cứu

Đề tài giới hạn trong việc phân tích dữ liệu định lượng, không xét đến các yếu tố định tính như nhân khẩu học hay sở thích cá nhân. Thuật toán phân cụm được sử dụng là **K-Means**, không mở rộng sang các mô hình phức tạp khác. Dữ liệu nghiên cứu tập trung trong lĩnh vực bán lẻ hoặc thương mại điện tử.

1.5. Phương pháp nghiên cứu

Để đảm bảo tính logic, khách quan và khoa học cho toàn bộ quá trình thực hiện đề tài, nhóm nghiên cứu đã vận dụng kết hợp nhiều phương pháp nghiên cứu khác nhau, bao gồm cả lý thuyết và thực nghiệm. Mỗi phương pháp đóng vai trò bổ trợ nhằm xây dựng một mô hình phân khúc khách hàng hiệu quả, có khả năng áp dụng thực tiễn và đánh giá được bằng các tiêu chí định lượng cụ thể.

1.5.1. Phương pháp nghiên cứu sơ bộ

Ở giai đoạn đầu, nhóm thực hiện tiến hành khảo sát tổng quan các công trình nghiên cứu và ứng dụng liên quan đến mô hình RFM và thuật toán K-Means. Việc khảo sát giúp định hình phạm vi nghiên cứu, lựa chọn hướng tiếp cận phù hợp, đồng thời xác định các yếu tố then chốt cần tập trung như cách tính chỉ số RFM, phương pháp chuẩn hóa, cũng như các tiêu chí đánh giá mô hình phân cụm.

1.5.2. Phương pháp nghiên cứu tài liệu

Phương pháp này đóng vai trò cung cấp nền tảng lý thuyết vững chắc cho đề tài. Nhóm nghiên cứu tiến hành thu thập, chọn lọc và tổng hợp các tài liệu học thuật, giáo trình, bài báo khoa học quốc tế cũng như các báo cáo ứng dụng thực tiễn từ doanh nghiệp và tổ chức nghiên cứu. Việc nghiên cứu tài liệu không chỉ giúp hiểu rõ bản chất mô hình RFM và thuật toán K-Means mà còn hỗ trợ nhận diện được các ưu, nhược điểm cũng như điều kiện áp dụng hiệu quả.

1.5.3. Phương pháp nghiên cứu thống kê

Dữ liệu đầu vào của đề tài là tập dữ liệu khách hàng thực tế, do đó việc áp dụng các kỹ thuật thống kê là điều cần thiết để xử lý, khám phá và làm sạch dữ liệu. Cụ thể, nhóm sử dụng các phương pháp thống kê mô tả để phân tích đặc điểm tổng quan của dữ liệu, kiểm tra tính đầy đủ, phát hiện ngoại lệ và kiểm tra phân phối các biến số RFM. Những kỹ thuật như biểu đồ hộp (boxplot), biểu đồ phân phối, và hệ số tương quan cũng được dùng để hỗ trợ việc hiểu rõ cấu trúc dữ liệu trước khi đưa vào mô hình.

1.5.4. Phương pháp thực nghiệm

Đây là giai đoạn trọng tâm trong quá trình triển khai đề tài. Dựa trên tập dữ liệu đã được tiền xử lý, nhóm tiến hành tính toán các chỉ số RFM theo từng khách hàng, chuẩn hóa dữ liệu bằng phương pháp Z-score nhằm đảm bảo tính đồng đều về thang đo giữa các biến. Sau đó, thuật toán K-Means được áp dụng để phân cụm khách hàng dựa trên hành vi tiêu dùng. Việc lựa chọn số lượng cụm tối ưu được thực hiện thông qua nhiều kỹ thuật hỗ trợ như **Elbow Method**, **Silhouette Score**,...

1.5.5. Phương pháp đánh giá

Sau khi hoàn tất quá trình phân cụm, nhóm thực hiện đánh giá chất lượng kết quả thông qua các chỉ số định lượng phổ biến trong học máy. Trong đó, Silhouette Score phản ánh mức độ gắn kết nội cụm và tách biệt liên cụm, Calinski–Harabasz Index đo lường mức độ phân tách giữa các cụm, còn Davies–Bouldin Index đánh giá sự chồng lấn giữa các cụm. Việc đánh giá định lượng giúp đảm bảo rằng mô hình không chỉ phân cụm một cách hình thức mà còn có giá trị sử dụng thực tế trong việc nhận diện các nhóm khách hàng khác biệt về hành vi.

1.6. Đóng góp của đề tài

1.6.1. Trong lĩnh vực học thuật

Đề tài là minh chứng cụ thể cho khả năng ứng dụng lý thuyết vào thực tiễn, đồng thời bổ sung thêm một ví dụ điển hình về mô hình RFM kết hợp K-Means trong phân tích hành vi người tiêu dùng. Đây cũng là nguồn tài liệu tham khảo hữu ích cho sinh viên, giảng viên và nhà nghiên cứu trong lĩnh vực khoa học dữ liệu và marketing phân tích.

1.6.2. Trong thực tiễn kinh doanh

Với cách tiếp cận rõ ràng và quy trình cụ thể, đề tài có thể hỗ trợ doanh nghiệp trong việc ra quyết định chiến lược dựa trên dữ liệu thực tế. Kết quả phân cụm giúp nhận diện các nhóm khách hàng tiềm năng, từ đó triển khai chiến lược tiếp thị cá nhân hóa, nâng cao tỷ lệ giữ chân khách hàng, và tối ưu hóa chi phí chăm sóc.

CHƯƠNG 2: TỔNG QUAN LÝ THUYẾT

2.1 Phân tích hành vi khách hàng và tầm quan trọng của phân khúc

Hành vi khách hàng là toàn bộ quá trình suy nghĩ, ra quyết định và hành động của người tiêu dùng trong việc tiếp cận, mua và sử dụng sản phẩm hoặc dịch vụ. Việc thấu hiểu hành vi này giúp doanh nghiệp:

- Dự đoán chính xác nhu cầu thị trường
- Điều chỉnh chiến lược tiếp cận khách hàng
- Tối ưu hóa hiệu quả kinh doanh.

Trong thời đại dữ liệu số, phân tích hành vi không còn dựa vào quan sát trực tiếp mà chủ yếu dựa vào **phân tích dữ liệu lịch sử mua sắm** của khách hàng [1].

Phân khúc khách hàng (Customer Segmentation) là quá trình chia nhỏ thị trường thành các nhóm khách hàng có đặc điểm tương đồng thường dựa trên hành vi tiêu dùng, nhu cầu, giá trị đơn hàng hoặc tần suất mua sắm. Mục tiêu của việc phân khúc là giúp doanh nghiệp:


- Xây dựng chiến lược tiếp thị mục tiêu
- Tối ưu chi phí marketing
- Nâng cao trải nghiệm khách hàng.

Theo khảo sát của **TechTarget**, doanh nghiệp áp dụng chiến lược phân khúc bài bản có thể **tăng tỷ lệ giữ chân khách hàng lên đến 30%** so với các doanh nghiệp không thực hiện phân khúc.

Một số lợi ích cụ thể của phân khúc khách hàng:

- **Tập trung đúng đối tượng:** Tối ưu ngân sách, tăng hiệu quả tiếp thị.
- **Cá nhân hóa trải nghiệm:** Nâng cao sự hài lòng, tăng mức độ trung thành.
- **Mở rộng thị trường:** Tận dụng hiệu quả từ các phân khúc hiện tại để mở rộng ra tệp khách hàng mới.[2]

2.1.1 Các hình thức phân khúc khách hàng



Hình 1: Các hình thức phân khúc khách hàng


Dưới đây là ba phương pháp tiếp cận phổ biến trong phân khúc khách hàng:

Phương pháp	Đặc điểm chính	Ứng dụng
Persona-based	Định tính, dựa trên hồ sơ khách hàng mẫu	Dữ liệu hạn chế hoặc nghiên cứu sơ khởi
Behavior-based	Định lượng, dựa vào dữ liệu hành vi thực tế (ví dụ: RFM)	Phân tích từ dữ liệu giao dịch
Predictive	Dự đoán xu hướng tương lai (như khả năng mua, rời bỏ, nhấp chuột)	Dùng khi có dữ liệu lớn và mô hình dự đoán

Trong thực tế, tiếp cận phân khúc theo hành vi (**behavior-based segmentation**) bằng mô hình RFM là một phương pháp phổ biến, đặc biệt phù hợp khi có sẵn dữ liệu lịch sử giao dịch. Phương pháp này giúp nhóm khách hàng theo đặc điểm tiêu dùng thực tế dựa trên ba yếu tố: Recency (gần nhất), Frequency (tần suất mua hàng), và Monetary (giá trị chi tiêu).

2.2. Mô hình RFM

Mô hình **RFM** (*Recency – Frequency – Monetary*) là một phương pháp phân tích hành vi khách hàng phổ biến trong các lĩnh vực như thương mại điện tử, ngân hàng, bán lẻ và tiếp thị trực tiếp. Dựa trên nguyên lý **Pareto (80/20)** cho rằng **20% khách hàng tạo ra 80% doanh số**, mô hình này giúp doanh nghiệp xác định nhóm khách hàng mang lại giá trị cao nhất, từ đó phân bổ nguồn lực phù hợp để tối ưu hóa hiệu quả kinh doanh.



Hình 2: Mô hình RFM

- **Recency (R):** Thể hiện khoảng thời gian kể từ lần giao dịch gần nhất. Khách hàng có chỉ số Recency thấp thường vẫn còn tương tác tích cực với doanh nghiệp, trong khi giá trị cao có thể là tín hiệu cảnh báo về khả năng rời bỏ.
- **Frequency (F):** Đo lường số lần mua hàng trong khoảng thời gian xác định. Tần suất cao thường đồng nghĩa với mức độ trung thành cao.
- **Monetary (M):** Đại diện cho tổng giá trị chi tiêu. Đây là chỉ số quan trọng nhất phản ánh mức độ đóng góp thực tế của khách hàng vào doanh thu.

Các tổ chức lớn thường triển khai phân khúc khách hàng dựa trên các mức RFM khác nhau. Chẳng hạn, trong ngành ngân hàng, khách hàng có thể được phân thành các nhóm như *Mass*, *Affluent* và *Priority* để phục vụ theo từng cấp độ giá trị. Ở lĩnh vực chứng khoán, các nhóm khách hàng được chia theo tài sản ròng (*NAV*). Việc này không chỉ giúp tăng sự hài lòng mà còn tạo điều kiện để phát triển các sản phẩm/dịch vụ phù hợp với từng phân khúc.[3]

Trong các bài toán phân tích khách hàng, mô hình RFM thường được sử dụng như một công cụ **rút trích đặc trưng định lượng đầu vào** cho các thuật toán phân cụm như **K-Means**. Việc mã hóa mỗi khách hàng thông qua ba chỉ số **R**, **F** và **M** cho phép mô hình nhóm các cá nhân có hành vi tiêu dùng tương đồng một cách hiệu quả. Phương pháp này có tính khả thi cao, không yêu cầu dữ liệu nhạy cảm và đặc biệt phù hợp trong các bối cảnh thực tế cần phân khúc hành vi khách hàng.

2.2.1 Ưu điểm của RFM

Mô hình RFM mang lại nhiều lợi ích trong phân tích hành vi khách hàng và tối ưu chiến lược tiếp thị. Theo **Harvard Business School**, việc tập trung vào nhóm khách hàng có giá trị cao có thể: **Tăng tỷ lệ chuyển đổi lên tới 750%** và **Tăng doanh thu đến 300%**.[4]

Mô hình RFM hỗ trợ doanh nghiệp xác định các nhóm khách hàng trọng yếu như **Champions**, **Loyal Customers** hay **At-Risk Customers**, từ đó triển khai các chương trình giữ chân phù hợp.[5]. Theo nghiên cứu của **Bain & Company**, chỉ cần tăng 5% tỷ lệ duy trì khách hàng cũng có thể mang lại mức tăng lợi nhuận từ 25% đến 95%. [6]

Nhờ khả năng **định lượng hành vi và giá trị khách hàng**, RFM tạo nền tảng vững chắc cho các chiến lược tiếp cận cá nhân hóa và xây dựng mối quan hệ dài hạn với khách hàng mục tiêu. [7]

2.3. Chuẩn hóa dữ liệu (Standardization)

Trong học máy và khai thác dữ liệu, chuẩn hóa là bước tiền xử lý quan trọng nhằm đưa các đặc trưng về cùng thang đo. Điều này đặc biệt cần thiết khi dữ liệu có các đơn vị đo khác nhau, tránh việc các đặc trưng có giá trị lớn chi phối mô hình.

Với các thuật toán dựa trên khoảng cách hoặc đạo hàm như K-Means, PCA hay mạng nơ-ron, chuẩn hóa không chỉ tăng độ chính xác và tốc độ huấn luyện mà còn đảm bảo sự công bằng giữa các đặc trưng. Về nguyên tắc, chuẩn hóa không làm thay đổi quan hệ tương đối giữa các giá trị, mà giúp điều chỉnh dữ liệu sao cho phù hợp về hình học và thống kê.

2.3.1. Cơ sở toán học của chuẩn hóa

Phương pháp chuẩn hóa được sử dụng phổ biến nhất là chuẩn hóa theo phân phối chuẩn (**z-score normalization**). Kỹ thuật này chuyển các giá trị của một đặc trưng về một thang đo mới có trung bình bằng 0 và độ lệch chuẩn bằng 1, theo công thức:

$$z = \frac{x - \mu}{\sigma}$$

Trong đó:

- x : là giá trị gốc của một điểm dữ liệu.
- μ : là trung bình của toàn bộ đặc trưng đó.
- σ : là độ lệch chuẩn tương ứng.

Việc chuẩn hóa theo **z-score** giúp tái định hình phân phối dữ liệu theo hướng loại bỏ ảnh hưởng của đơn vị đo lường và quy mô, qua đó tạo điều kiện thuận lợi cho các thuật toán phân tích hoạt động hiệu quả và ổn định hơn.

2.3.2. Lợi ích khi áp dụng chuẩn hóa

Chuẩn hóa dữ liệu mang lại nhiều lợi thế trong quá trình xây dựng mô hình học máy:

- **Cân bằng ảnh hưởng giữa các đặc trưng:** Đảm bảo rằng không có biến nào chiếm ưu thế chỉ vì quy mô giá trị lớn hơn các biến khác.
- **Giảm sai số số học trong tính toán:** Giúp giảm thiểu các lỗi liên quan đến làm tròn hoặc độ chính xác máy tính trong các phép tính ma trận.
- **Tăng tốc độ hội tụ trong huấn luyện:** Đặc biệt quan trọng với các thuật toán tối ưu hóa gradient như SGD.
- **Hỗ trợ phân tích trực quan tốt hơn:** Việc dữ liệu nằm trong cùng một khoảng giá trị giúp biểu đồ và mô hình trực quan dễ đọc, dễ phân tích.

2.3.3. Hạn chế và điểm cần lưu ý

Dù cần thiết trong nhiều trường hợp, chuẩn hóa dữ liệu cũng có một số điểm bất lợi. Việc loại bỏ đơn vị gốc khiến các giá trị trở nên khó diễn giải trực quan. Bên cạnh đó, với các thuật toán không dựa vào khoảng cách như cây quyết định hay rừng ngẫu nhiên, chuẩn hóa không bắt buộc. Ngoài ra, phương pháp z-score dễ bị sai lệch nếu dữ liệu chứa nhiều ngoại lệ, do phụ thuộc vào giá trị trung bình và độ lệch chuẩn.


2.3.4. Vai trò trong các thuật toán học máy

Chuẩn hóa đóng vai trò quan trọng trong các mô hình học máy sử dụng khoảng cách (K-Means, KNN), tối ưu hóa đạo hàm (hồi quy tuyến tính, logistic, deep learning), hoặc giảm chiều (PCA). Việc đưa các đặc trưng về cùng thang đo giúp đảm bảo sự cân bằng trong đóng góp của mỗi biến, từ đó nâng cao độ chính xác và ổn định của mô hình.[8]

2.4. Ngoại lệ trong dữ liệu và vai trò trong phân tích

2.4.1. Khái niệm ngoại lệ (Outlier)

Trong thống kê và phân tích dữ liệu, **(outlier)** là những điểm dữ liệu có giá trị lệch một cách bất thường so với phần lớn các điểm còn lại trong tập dữ liệu. Những điểm này có thể là kết quả của lỗi đo lường, lỗi nhập liệu, hoặc phản ánh một hành vi đặc biệt trong thực tế.



Hình 3: Minh họa về outlier

Tùy theo ngữ cảnh, **(outlier)** có thể chứa thông tin giá trị (ví dụ: khách hàng VIP chi tiêu cao bất thường) hoặc chỉ đơn thuần là nhiễu cần được loại bỏ.[9]

2.4.2. Tác động của ngoại lệ đến phân tích và mô hình học máy


Sự tồn tại của các giá trị ngoại lệ có thể **làm sai lệch kết quả phân tích**, đặc biệt trong các mô hình dựa trên khoảng cách (K-Means, KNN) hoặc độ lệch trung bình. Ngoại lệ có thể:

- Làm lệch **trung tâm cụm (centroid)** trong phân cụm K-Means.
- Gây ra hiện tượng **mô hình học bị lệch hoặc quá khớp**.
- Làm sai số trong **ước lượng thống kê** như trung bình hoặc phương sai.

Do đó, nhận diện và xử lý ngoại lệ là bước cần thiết trong tiền xử lý dữ liệu.

2.4.3. Phương pháp phát hiện ngoại lệ

Một kỹ thuật phổ biến trong thống kê mô tả để phát hiện ngoại lệ là **IQR (Interquartile Range)**, dựa trên các tứ phân vị:



Hình 4: Phát hiện giá trị ngoại lệ bằng phương pháp IQR (Interquartile Range).

$$IQR = Q3 - Q1$$

$$\text{Outlier if } x < Q1 - 1.5 \times IQR \quad \text{or} \quad x > Q3 + 1.5 \times IQR$$

Trong đó:

- $Q1$: tứ phân vị thứ nhất (25% dưới cùng).
- $Q3$: tứ phân vị thứ ba (75% dưới cùng).
- x : giá trị quan sát.

Bên cạnh đó, các phương pháp khác như **z-score**, **Mahalanobis distance**, hoặc trực quan hóa bằng **boxplot**, **scatter plot** cũng được sử dụng trong thực hành phân tích dữ liệu.[10]

2.4.4. Ưu điểm và nhược điểm của việc xử lý ngoại lệ

Ưu điểm:

- **Cải thiện độ chính xác mô hình:** Khi loại bỏ nhiễu, mô hình học máy phản ánh đúng hơn mối quan hệ trong dữ liệu.
- **Tăng độ ổn định và khả năng tổng quát:** Hạn chế ảnh hưởng tiêu cực từ các điểm quá khác biệt.
- **Hỗ trợ phát hiện hành vi đặc biệt:** Có thể sử dụng để phát hiện gian lận, khách hàng đặc biệt, hoặc bất thường trong sản xuất.

Nhược điểm:

- **Nguy cơ mất thông tin giá trị:** Một số ngoại lệ không phải lỗi mà phản ánh hành vi thật sự (ví dụ: khách hàng VIP).
- **Phụ thuộc vào ngữ cảnh và ngành:** Không có quy tắc chung cho việc giữ hay loại bỏ — quyết định xử lý cần dựa vào hiểu biết nghiệp vụ.
- **Một số phương pháp phát hiện phụ thuộc phân phối dữ liệu:** Ví dụ, z-score giả định dữ liệu phân phối chuẩn nên không phù hợp với phân phối lệch.

2.4.5. Vai trò của xử lý ngoại lệ trong quá trình phân tích

Việc xử lý ngoại lệ là một phần quan trọng trong tiền xử lý dữ liệu. Đặc biệt trong các mô hình phân cụm như **K-Means**, việc giữ lại các điểm dữ liệu gây nhiễu có thể ảnh hưởng tiêu cực đến vị trí tâm cụm và kết quả phân nhóm. Bằng cách xác định và xử lý thích hợp các điểm ngoại lệ, nhà phân tích có thể:


- Cải thiện độ chính xác của mô hình.
- Giảm sai số trong ước lượng thống kê.
- Nâng cao khả năng nhận diện hành vi đặc trưng trong tập khách hàng.

Việc xử lý ngoại lệ cần thận trọng và kết hợp với kiến thức chuyên ngành để tránh làm mất dữ liệu quan trọng.

2.5. Thuật toán phân cụm K – Means

2.5.1. Khái niệm về K – Means

Thuật toán K-means là một kỹ thuật học không giám sát nổi bật, được ứng dụng rộng rãi trong phân tích dữ liệu nhằm chia tập dữ liệu chưa gán nhãn thành các nhóm (cụm) sao cho các điểm dữ liệu trong cùng một cụm có mức độ tương đồng cao, trong khi sự khác biệt giữa các cụm là tối đa. Nguyên lý hoạt động của K-means dựa trên việc tối thiểu hóa tổng bình phương khoảng cách giữa các điểm dữ liệu và tâm cụm mà chúng được gán vào. Mỗi điểm sẽ được phân vào cụm có trung tâm gần nhất, và các tâm cụm được cập nhật liên tục cho đến khi đạt được trạng thái hội tụ.[11]



Hình 5: Minh họa về K - Means

Mục tiêu chính của K-Means là giảm thiểu tổng bình phương khoảng cách giữa các điểm dữ liệu và trung tâm cụm của chúng, được gọi là Within-Cluster Sum of Squares (WCSS):

$$WCSS = \sum_{i=1}^K \sum_{x \in C_i} \|x - \mu_i\|^2$$

Trong đó:

- K : Là số lượng cụm
- C_i : Là tập hợp các điểm thuộc cụm thứ i
- μ_i : Là trung tâm (tâm cụm) của cụm thứ i
- $\|x - \mu_i\|^2$: Là bình phương khoảng cách Euclidean giữa điểm x và tâm cụm μ_i


2.5.2. Cách hoạt động của K-Means

Bước 1: Chọn số lượng cụm

- Xác định số lượng cụm K mà ta sẽ nhóm dữ liệu. Ví dụ chọn $K = 3$.

Bước 2: Khởi tạo tâm cụm ban đầu


- Do vị trí chính xác của các tâm cụm chưa được biết, nên ở giai đoạn khởi tạo, thuật toán sẽ chọn ngẫu nhiên K điểm từ tập dữ liệu và coi đó là các tâm cụm ban đầu.



Hình 6: Ví dụ minh họa về khởi tạo tâm cụm

Bước 3: Gán điểm dữ liệu cho cụm gần nhất

- Sau khi đã có tâm cụm ban đầu, mỗi điểm dữ liệu sẽ được gán vào cụm có tâm gần nhất. Khoảng cách giữa điểm dữ liệu và tâm cụm thường được đo bằng khoảng cách Euclidean. Điểm dữ liệu sẽ thuộc về cụm có tâm mà nó có khoảng cách Euclidean ngắn nhất.



Hình 7: Ví dụ về gán điểm dữ liệu cho cụm gần nhất

- Đo khoảng cách từ các điểm tới tâm cụm bằng phép đo khoảng cách Euclidean.

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

- Sau đó chọn cụm cho dữ liệu có khoảng cách giữa các điểm dữ liệu và tâm nhỏ nhất.



Hình 8: Sau khi đo khoảng cách tâm tới điểm dữ liệu


Bước 4: Khởi tạo lại tâm cụm

- Khởi tạo lại trọng tâm bằng cách tính toán giá trị trung bình của tất cả các điểm dữ liệu của cụm đó.

$$C_i = \frac{1}{|N_i|} \sum x_i$$

Trong đó:

- C_i : là tâm cụm thứ i (centroid của cụm i)
- N_i : là tập các điểm thuộc cụm i
- $|N_i|$: là số lượng điểm trong cụm i (kích thước cụm)
- $\sum x_i$: là tổng các vector dữ liệu x_i trong cụm i



Hình 9: Sau khi khởi tạo lại tâm cụm

Bước 5: Lặp lại

- Tiến hành lặp lại bước 3 và bước 4 cho đến khi có được trọng tâm tối ưu và việc chỉ định các điểm dữ liệu cho các cụm chính xác không còn thay đổi.[12]

2.5.3. Lựa chọn số cụm K trong K -Means

Một trong những yếu tố quan trọng ảnh hưởng đến hiệu quả phân cụm trong thuật toán K -Means là số lượng cụm K . Nếu K được lựa chọn không hợp lý, mô hình có thể bỏ sót hoặc chia nhỏ không cần thiết các nhóm khách hàng tiềm năng. Do đó, việc xác định số cụm tối ưu là một bước thiết yếu trong quy trình phân tích. Các phương pháp đánh giá phổ biến sẽ được trình bày chi tiết trong phần 2.6.



Hình 10: Hoàn thành quá trình phân cụm

2.5.4. Ưu điểm và nhược điểm của K-Means

Ưu điểm:

- **Đơn giản và dễ triển khai:** K-Means là một trong những thuật toán phân cụm phổ biến và dễ hiểu nhất.
- **Tốc độ xử lý nhanh:** Nhờ cấu trúc tính toán hiệu quả, K-Means có thể xử lý nhanh với dữ liệu lớn và số cụm nhỏ.
- **Khả năng mở rộng tốt:** Có thể áp dụng cho dữ liệu lớn hoặc phân cụm theo batch.
- **Linh hoạt:** Có thể áp dụng cho nhiều loại dữ liệu sau khi chuẩn hóa và chuyển đổi thích hợp.

Nhược điểm:

- **Phải xác định trước số cụm K :** Đây là yêu cầu bắt buộc và gây khó khăn khi chưa hiểu rõ dữ liệu.
- **Phụ thuộc vào khởi tạo ban đầu:** Kết quả phân cụm bị ảnh hưởng bởi cách chọn tâm cụm ban đầu.
- **Giả định cụm hình cầu:** K-Means hoạt động tốt khi các cụm có hình dạng đối xứng, đồng đều và không chồng lấn.
- **Nhạy cảm với outliers:** Các điểm ngoại lai có thể làm lệch tâm cụm và ảnh hưởng đáng kể đến kết quả phân cụm.[13]

2.5.5. Ứng dụng của K-Means trong thực tế

K-Means là thuật toán phân cụm phổ biến, đặc biệt hiệu quả với **dữ liệu số và liên tục**. Nó được ứng dụng rộng rãi trong nhiều lĩnh vực:

- **Phân khúc khách hàng:** Nhóm người dùng theo hành vi tiêu dùng, hỗ trợ **cá nhân hóa marketing** và **nâng cao dịch vụ**.
- **Phát hiện bất thường:** Tìm ra các giao dịch gian lận hoặc truy cập trái phép trong tài chính và bảo mật..
- **Phân loại tài liệu:** Trong NLP, K-Means giúp **nhóm tài liệu theo chủ đề** dựa trên đặc trưng ngôn ngữ.
- **Phân tích dữ liệu không gian và hình ảnh:** Phân vùng ảnh theo màu sắc/độ sáng, hữu ích trong thị giác máy và chẩn đoán y khoa.[14]

2.5.6. Giả định của thuật toán K-Means

Để hoạt động hiệu quả, thuật toán K-Means ngầm định một số giả thiết về phân bố dữ liệu:

- **Cụm có dạng hình cầu** (hình elip đẳng phương): Các cụm phải có phương sai đồng đều và tách biệt rõ ràng theo khoảng cách Euclidean.
- **Kích thước cụm tương đương**: Nếu các cụm có mật độ điểm quá khác nhau, K-Means có thể phân chia sai.
- **Không có nhiễu mạnh (outliers)**: Do K-Means sử dụng trung bình cụm làm đại diện, nên dễ bị lệch bởi các giá trị cực đoan.
- **Dữ liệu số và liên tục**: K-Means không hoạt động tốt với dữ liệu phân loại hoặc thứ bậc trừ khi được mã hóa lại phù hợp.

Việc hiểu rõ các giả định này giúp nhà phân tích lựa chọn đúng thuật toán hoặc tiền xử lý dữ liệu tương ứng để đảm bảo hiệu quả phân cụm.

2.5.7. K-Means trong phân khúc khách hàng dựa trên mô hình RFM

K-Means là thuật toán phân cụm hiệu quả, đặc biệt phù hợp để phân khúc khách hàng khi sử dụng mô hình RFM gồm ba chỉ số: Recency (thời gian mua hàng gần nhất), Frequency (tần suất mua hàng), và Monetary (giá trị chi tiêu).


Sau khi chuẩn hóa các chỉ số RFM để đảm bảo cùng thang đo, K-Means có thể nhóm khách hàng thành các cụm có hành vi tương đồng. Một số phân khúc điển hình:

- **Khách hàng ưu tiên (Champions)**: Mua gần đây, thường xuyên, chi tiêu cao
- **Khách hàng trung thành (Loyal Customers)**: Mua gần đây, thường xuyên, chi tiêu cao
- **Khách hàng có rủi ro rời bỏ (At-Risk)**: Mua gần đây, thường xuyên, chi tiêu cao
- **Khách hàng mới (New Customers)**: Mua gần đây, thường xuyên, chi tiêu cao

Kết quả phân cụm giúp doanh nghiệp hiểu rõ cấu trúc khách hàng và xây dựng các chiến lược tiếp cận, chăm sóc, giữ chân hiệu quả hơn.

2.6. Các phương pháp chọn số cụm tối ưu

Việc xác định số cụm K hợp lý là yếu tố then chốt trong phân cụm. Nếu K quá nhỏ, mô hình bỏ sót các nhóm tiềm năng; nếu quá lớn, dễ dẫn đến quá khớp và mất tính khái quát. Để chọn được K tối ưu, có thể áp dụng một số phương pháp phổ biến như Elbow, Silhouette, Calinski-Harabasz và Davies-Bouldin.



Hình 11: Elbow method

2.6.1. Phương pháp Elbow (Khủy tay)

Tìm số lượng cụm sao cho tổng phương sai trong cụm (WSS – within-cluster sum of squares) là nhỏ nhất, nhưng không giảm quá nhiều khi tăng thêm cụm.

Công thức WCSS:

$$WCSS = \sum_{i=1}^K \sum_{x \in C_i} \|x - \mu_i\|^2$$

Cách thực hiện:

1. Thực hiện phân cụm với các giá trị K khác nhau (ví dụ từ 1 đến 10).
2. Tính tổng WSS cho mỗi K.
3. Vẽ biểu đồ WSS theo số cụm K.
4. Điểm “gấp khúc” (elbow) trên đồ thị thường là nơi phù hợp để chọn K.

Ứng dụng của phương pháp Elbow

Phương pháp Elbow hữu ích trong các trường hợp sau:

- **Học không giám sát:** Khi làm việc với dữ liệu chưa được gán nhãn.
- **Phân tích dữ liệu thăm dò (EDA):** Dùng để xác định số lượng cụm khi không biết trước.
- **Phân cụm K-Means:** Phương pháp chính thường dùng cho K-Means.
- **Xử lý dữ liệu ở giữa chừng:** Sử dụng sau khi làm sạch dữ liệu nhưng trước khi mô hình hóa phức tạp hơn.


Hạn chế của Elbow

Dù dễ áp dụng, phương pháp Elbow có hạn chế:

- **Tính chủ quan:** Điểm khuỷu tay có thể khó xác định khi đồ thị không rõ ràng.
- **Giả định hình cầu:** Không phù hợp với các cụm không đồng đều.
- **Tính đa chiều:** Dữ liệu có nhiều chiều có thể gây biến dạng hình khuỷu tay.
- **Chi phí tính toán:** Tính WCSS cho nhiều giá trị k tốn kém, đặc biệt với dữ liệu lớn.[15]

2.6.2. Phương pháp Silhouette

Đánh giá mức độ phù hợp của từng điểm dữ liệu với cụm của nó. Giá trị Silhouette càng gần 1 cho thấy điểm đó nằm “đúng” trong cụm hơn.



Hình 12: Silhoutte Plot

Cách thực hiện:

1. Phân cụm dữ liệu với các giá trị khác nhau.
2. Tính độ rộng silhouette trung bình cho mỗi giá trị K.
3. Vẽ đồ thị silhouette theo K.
4. Chọn K tại vị trí có giá trị silhouette trung bình lớn nhất.

Công thức Silhouette:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Trong đó:

$a(i)$: Khoảng cách trung bình từ điểm i đến tất cả các điểm khác trong **cùng cụm**.

$b(i)$: Khoảng cách trung bình nhỏ nhất từ điểm i đến các điểm trong **cụm khác gần nhất**.

- **Kết quả Silhouette trả về nằm trong khoảng $[-1, 1]$:**
 - Gần **1**: Điểm dữ liệu được phân cụm **rất tốt**.
 - Gần **0**: Điểm dữ liệu nằm ở **ranh giới giữa hai cụm**.
 - Gần **-1**: Điểm dữ liệu có thể bị **phân cụm sai hoàn toàn**.
- **Đánh giá chất lượng phân cụm dựa trên Silhouette trung bình:**
 - **0.71 – 1.00**: Cấu trúc phân cụm **mạnh**.
 - **0.51 – 0.70**: Cấu trúc phân cụm **hợp lý**.
 - **0.26 – 0.50**: Cấu trúc phân cụm **yếu**, nên **xem xét lại**.
 - **≤ 0.25** : **Không phát hiện được** cấu trúc phân cụm rõ ràng.

Hạn chế của phương pháp Silhouette


- **Khó xác định số cụm tối ưu khi dữ liệu có cấu trúc phức tạp:** Trong trường hợp các cụm có hình dạng không đồng nhất hoặc không hình cầu, Silhouette Score có thể không đưa ra kết quả chính xác về số lượng cụm tối ưu.
- **Độ phức tạp tính toán:** Tính toán Silhouette Score cho toàn bộ tập dữ liệu có thể tốn kém về thời gian và tài nguyên, đặc biệt đối với các tập dữ liệu lớn

Ứng dụng thực tế

- Phương pháp Silhouette Score thường được sử dụng cùng với các phương pháp khác như Elbow Method để xác định số lượng cụm tối ưu trong phân tích phân cụm, đặc biệt là khi dữ liệu có sự chồng lấn giữa các nhóm.[16]

2.6.3. Phương pháp Calinski–Harabasz (CH Index)

Phương pháp **Calinski-Harabasz Index (CH Index)** là một chỉ số đánh giá chất lượng phân cụm, được sử dụng để đo lường mức độ phân tách giữa các cụm và độ gắn kết nội bộ trong mỗi cụm. Chỉ số này càng cao thì chất lượng phân cụm càng tốt, vì nó cho thấy rằng các cụm có sự tách biệt rõ ràng và đồng thời các điểm dữ liệu trong cùng một cụm có tính đồng nhất cao.



Hình 13: Calinski–Harabasz

Công thức:

$$CH = \frac{BCSS/(K - 1)}{WCSS/(n - K)}$$

Trong đó:

- **BCSS (Between-Cluster Sum of Squares):** Phương sai giữa các cụm, đo lường sự phân tách giữa các cụm. BCSS càng lớn, các cụm càng phân tách rõ ràng.

$$BCSS = \sum_{i=1}^k n_i (\mu_i - \mu)^2$$

- Trong đó:
 - n_i : Số điểm dữ liệu trong cụm i .

- μ_i : Tâm của cụm i .
- μ : Tâm trung bình của toàn bộ dữ liệu
- **WCSS (Within-Cluster Sum of Squares)**: Phương sai trong các cụm, đo lường sự đồng nhất của các điểm trong cùng một cụm. WCSS càng nhỏ, các điểm trong mỗi cụm càng đồng nhất.

$$\text{WCSS} = \sum_{i=1}^k \sum_{x \in C_i} (x - \mu_i)^2$$

- Trong đó:
 - C_i : Tập hợp các điểm dữ liệu trong cụm i .
 - μ_i : Tâm của cụm i .
 - x : Một điểm dữ liệu trong cụm i .
- K : số cụm.
- n : số lượng điểm dữ liệu.

Ý nghĩa của Calinski-Harabasz Index

- **Giá trị cao**: CH Index cao cho thấy các cụm có sự phân tách rõ ràng và các điểm trong mỗi cụm có tính đồng nhất cao, tức là phân cụm tốt.
- **Giá trị thấp**: CH Index thấp cho thấy các cụm có sự chồng lấn hoặc các điểm dữ liệu trong cùng một cụm có sự khác biệt lớn, tức là phân cụm kém chất lượng

Ưu điểm

- **Đơn giản và dễ hiểu**: Công thức tính đơn giản và dễ triển khai.
- **Phù hợp với dữ liệu có nhiều chiều**: Calinski-Harabasz Index có thể được sử dụng hiệu quả với dữ liệu có nhiều chiều.

Hạn chế


- **Phụ thuộc vào số lượng điểm dữ liệu**: CH Index có thể bị ảnh hưởng bởi số lượng điểm dữ liệu, cần lưu ý khi so sánh các tập dữ liệu có kích thước khác nhau.
- **Không phù hợp với dữ liệu có cấu trúc phức tạp**: CH Index có thể không chính xác với dữ liệu có cấu trúc không đồng nhất hoặc phức tạp.

Ứng dụng thực tế

Calinski-Harabasz Index thường được sử dụng kết hợp với các phương pháp như **Elbow Method** và **Silhouette Score** để xác định số lượng cụm tối ưu trong phân tích phân cụm. Sự kết hợp giữa các chỉ số giúp chọn lựa số lượng cụm tối ưu một cách chính xác hơn.[17]

2.6.4. Chỉ số Davies–Bouldin (DBI)

Davies-Bouldin Index (DBI) là một chỉ số dùng để đánh giá chất lượng phân cụm trong thuật toán K-Means hoặc bất kỳ phương pháp phân cụm nào khác. Chỉ số này đo lường mức độ chồng lấn giữa các cụm và mức độ đồng nhất trong mỗi cụm. **Davies-Bouldin Index** càng thấp, thì phân cụm càng tốt, vì điều này cho thấy các cụm ít chồng lấn và có sự phân tách rõ ràng giữa các cụm.



Hình 14: Davies–Bouldin

Công thức:

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \frac{S_i + S_j}{d(C_i, C_j)}$$

Trong đó:

- k : Số lượng cụm.
- S_i : Độ phân tán nội cụm của cụm i , tính là phương sai giữa các điểm trong cụm i .
- $d(C_i, C_j)$: khoảng cách giữa tâm cụm i và j .
- C_i : Các cụm khác nhau

Ý nghĩa của Davies-Bouldin Index

- **Giá trị thấp:** DBI thấp cho thấy các cụm có sự phân tách rõ ràng và ít chồng lấn, nghĩa là phân cụm tốt.
- **Giá trị cao:** DBI cao cho thấy có sự chồng lấn giữa các cụm và các cụm có sự phân tán lớn, nghĩa là phân cụm không tốt.

Ưu điểm:

- **Đơn giản và dễ sử dụng:** Chỉ số DBI dễ tính toán và triển khai, đặc biệt khi cần so sánh giữa nhiều số lượng cụm khác nhau.
- **Chỉ số trực quan:** Chỉ số này dễ dàng giải thích và sử dụng để đánh giá sự phân tách giữa các cụm.

Nhược điểm:

- **Không hoàn toàn chính xác khi các cụm không đồng đều:** DBI có thể không phản ánh chính xác chất lượng phân cụm khi các cụm có hình dạng không đồng nhất hoặc có sự phân tán rất khác nhau.
- **Chỉ số phụ thuộc vào khoảng cách giữa các cụm:** Khi khoảng cách giữa các cụm không rõ ràng hoặc dữ liệu có nhiều chiều, DBI có thể không phản ánh đúng mức độ phân tách của các cụm.


Ứng dụng thực tế

Davies-Bouldin Index thường được sử dụng để đánh giá chất lượng phân cụm khi cần đảm bảo rằng các cụm có sự phân tách rõ ràng và đồng nhất. DBI có thể kết hợp với các phương pháp khác như **Elbow Method** hoặc **Silhouette Score** để đưa ra quyết định chính xác hơn về số lượng cụm tối ưu.[18]

2.7. Kỹ thuật giảm chiều để trực quan hóa

Giảm chiều dữ liệu là quá trình chuyển đổi dữ liệu từ không gian nhiều chiều sang không gian ít chiều hơn, trong khi vẫn giữ lại các đặc trưng quan trọng. Phương pháp này giúp giảm độ phức tạp, loại bỏ nhiễu và tăng khả năng diễn giải.

Trong phân tích hành vi khách hàng bằng mô hình RFM (Recency, Frequency, Monetary), giảm chiều đặc biệt hữu ích cho trực quan hóa, giúp dễ dàng nhận diện cấu trúc dữ liệu và các nhóm khách hàng tiềm năng.[19]




Hình 15: Kỹ thuật giảm chiều

2.7.1. PCA (Principal Component Analysis).

Phân tích thành phần chính (PCA) là một kỹ thuật thống kê được sử dụng để giảm số chiều của dữ liệu đa chiều. PCA chuyển đổi dữ liệu gốc thành một tập hợp các thành phần chính – những hướng mới mà dữ liệu biến động nhiều nhất – đồng thời giữ lại càng nhiều thông tin (phương sai) càng tốt.

Cách hoạt động của PCA:

- **1. Chuẩn hóa dữ liệu:** Đưa các biến về cùng thang đo (trung bình = 0, độ lệch chuẩn = 1).
- **2. Tính ma trận hiệp phương sai:** Xác định mối quan hệ và mức độ phân tán giữa các biến.



Hình 16: PCA

- **3. Tính vector riêng và giá trị riêng:** Vector riêng cho biết hướng chính, giá trị riêng thể hiện mức độ biến động theo hướng đó.
- **4. Lựa chọn thành phần chính:** Các vector riêng ứng với giá trị riêng lớn nhất được chọn làm thành phần chính, giúp giảm số chiều dữ liệu trong khi giữ lại phần lớn thông tin quan trọng.
- **5. Chiều dữ liệu:** Vector riêng cho biết hướng chính, giá trị riêng thể hiện mức độ biến động theo hướng đó.

Ưu điểm của PCA:

- **Giảm chiều hiệu quả** mà vẫn bảo toàn phần lớn thông tin.
- **Tiết kiệm tài nguyên** tăng tốc xử lý và giảm chi phí tính toán
- **Giảm thiểu đa cộng tuyến** tăng tốc xử lý và giảm chi phí tính toán
- **Dễ hiểu và triển khai** được ứng dụng rộng rãi trong nhiều lĩnh vực
- **Hỗ trợ trực quan hóa** tốt ở không gian 2D/3D giúp phân tích dễ dàng hơn.

Khi nào nên sử dụng PCA


- Khi cần **giảm số biến đầu vào** nhưng vẫn giữ được phần lớn thông tin.
- Khi muốn **đơn giản hóa mô hình** và giảm chi phí tính toán.
- Khi xử lý **dữ liệu đa chiều** trong phân tích khám phá hoặc trực quan hóa.
- Khi cần **hạn chế hiện tượng quá khớp** và cải thiện độ ổn định của mô hình học máy.[20]

2.7.2. t-SNE (*t-distributed Stochastic Neighbor Embedding*).

Khái niệm về t-SNE

t-Distributed Stochastic Neighbor Embedding (t-SNE) là kỹ thuật giảm chiều phi tuyến, chủ yếu dùng để trực quan hóa dữ liệu đa chiều. Phương pháp này rất hiệu quả trong việc bảo toàn cấu trúc cục bộ và làm nổi bật các cụm trong dữ liệu nhiều chiều.

Cách hoạt động của t-SNE:



Hình 17: t-SNE

- **Tính toán độ tương đồng:** Chuyển khoảng cách giữa các điểm thành xác suất thể hiện mức độ gần nhau trong không gian cao chiều.
- **Ánh xạ chiều thấp:** Duy trì xác suất tương đồng trong không gian 2D/3D.
- **Tối ưu hóa:** Giảm sai lệch giữa hai phân phối bằng thuật toán giảm dần độ dốc.

Khi nào sử dụng t-SNE:

- Khi cần trực quan hóa dữ liệu nhiều chiều.
- Để phân biệt các nhóm/cụm dữ liệu tiềm ẩn.
- Khi muốn hiểu mối quan hệ nội tại trong dữ liệu.

Ưu điểm:

- Giữ được mối quan hệ cục bộ giữa các điểm dữ liệu.
- Phù hợp với dữ liệu phi tuyến và cấu trúc phức tạp.
- Giúp trực quan hóa rõ ràng các nhóm hoặc cụm nhỏ.

Nhược điểm:

- Tốn nhiều thời gian và tài nguyên với dữ liệu lớn.
- Nhạy cảm với tham số (perplexity).
- Không giữ cấu trúc toàn cục, khoảng cách giữa cụm có thể không chính xác.

Ứng dụng:

t-SNE thường dùng để trực quan hóa kết quả phân cụm khách hàng theo RFM, giúp nhận diện nhóm hành vi, ngoại lệ và đánh giá hiệu quả phân nhóm [20]

2.7.3. UMAP (Uniform Manifold Approximation and Projection).

Khái niệm

UMAP (Uniform Manifold Approximation and Projection) là một kỹ thuật giảm chiều không tuyến tính, được giới thiệu vào năm 2018 bởi McInnes, Healy và Melville. Mục tiêu của UMAP là biểu diễn dữ liệu nhiều chiều trong không gian 2D hoặc 3D, nhằm trực quan hóa hoặc phục vụ tiền xử lý cho các bài toán học máy.

Nguyên lý hoạt động

Thuật toán UMAP được xây dựng trên nền tảng lý thuyết tô pô đại số và hình học vi phân, với hai giả định chính:

- Dữ liệu phân bố trên một đa tạp trơn (*smooth manifold*) trong không gian nhiều chiều.
- Cấu trúc địa phương của dữ liệu có thể được bảo toàn thông qua xây dựng biểu đồ k-ê.

Quá trình thực thi bao gồm hai bước chính:

- **Xây dựng đồ thị lân cận** biểu diễn mối liên kết giữa các điểm gần nhau trong không gian gốc.
- **Tối ưu hóa đồ thị** trong không gian thấp chiều sao cho các mối liên hệ cục bộ và toàn cục được giữ lại tốt nhất có thể.

So sánh với PCA và t-SNE

Tiêu chí	PCA	t-SNE	UMAP
Bản chất	Tuyến tính	Phi tuyến	Phi tuyến
Cấu trúc bảo toàn	Toàn cục	Cục bộ	Cục bộ và toàn cục
Hiệu suất xử lý	Rất nhanh	Chậm với dữ liệu lớn	Nhanh hơn t-SNE
Khả năng tổng quát hóa	Hạn chế	Kém	Tốt (học embedding cho dữ liệu mới)
Ứng dụng phổ biến	Tiền xử lý	Trực quan hóa	Trực quan hóa, học biểu diễn đặc trưng

Ứng dụng

UMAP được sử dụng phổ biến trong các lĩnh vực như sinh học phân tử, tài chính, và phân tích hành vi người dùng – nơi dữ liệu có cấu trúc phức tạp và nhiều chiều. Nhờ khả năng bảo toàn tốt cả cấu trúc cục bộ lẫn toàn cục, UMAP thường được dùng để trực quan hóa và hỗ trợ phân cụm sau bước tiền xử lý dữ liệu. Ngoài ra, UMAP còn nổi bật với tốc độ nhanh, khả năng mở rộng cao, phù hợp cho các hệ thống khai phá dữ liệu quy mô lớn.[21]


CHƯƠNG 3: PHƯƠNG PHÁP THỰC NGHIỆM

3.1. Quá trình thực nghiệm

3.1.1. Mục tiêu của quá trình thực nghiệm

Quá trình thực nghiệm được thực hiện nhằm phân nhóm khách hàng dựa trên hành vi tiêu dùng. Bằng cách kết hợp mô hình RFM và thuật toán K-Means, mục tiêu là xác định các cụm khách hàng có đặc điểm tương đồng để phục vụ các chiến lược tiếp thị hiệu quả hơn.

3.1.2. Sơ đồ quy trình



Hình 18: Sơ đồ các bước thực hiện trong phân tích hành vi và phân cụm khách hàng.

3.2. Giới thiệu tập dữ liệu

3.2.1. Nguồn gốc và bối cảnh dữ liệu

Tập dữ liệu được sử dụng trong đề tài được lấy từ **UCI Machine Learning Repository**, thuộc nhóm dữ liệu **Online Retail**, ghi lại các giao dịch trong khoảng thời gian từ tháng 12/2010 đến tháng 12/2011 của một doanh nghiệp bán lẻ tại Anh. Dữ liệu phản ánh lịch sử mua sắm của khách hàng thông qua các hóa đơn điện tử, phù hợp để phân tích hành vi tiêu dùng.

3.2.2. Mô tả cấu trúc và các thuộc tính chính

Dữ liệu gồm **541.909 dòng** và **8 cột** chính:

- InvoiceNo: Mã số hóa đơn
- StockCode: Mã sản phẩm
- Description: Mô tả sản phẩm
- Quantity: Số lượng sản phẩm bán ra
- InvoiceDate: Ngày giao dịch
- UnitPrice: Giá đơn vị (tính bằng bảng Anh)
- CustomerID: Mã khách hàng
- Country: Quốc gia nơi khách hàng thực hiện giao dịch

3.2.3. Ý nghĩa các biến trong phân tích hành vi khách hàng

Trong bài toán phân khúc khách hàng, các biến quan trọng được sử dụng để tính chỉ số RFM bao gồm:

- InvoiceDate: Dùng để tính **Recency** - số ngày kể từ lần mua hàng gần nhất.
- InvoiceNo: Dùng để tính **Frequency** - số lần khách hàng thực hiện giao dịch.
- Quantity và UnitPrice: Kết hợp để tính **Monetary** - tổng giá trị chi tiêu.
- CustomerID: Khóa chính để nhóm và theo dõi từng khách hàng.

3.3. Khám phá dữ liệu

3.3.1. Thống kê mô tả tổng quan tập dữ liệu

Tập dữ liệu gồm hơn 500.000 dòng, ghi nhận các giao dịch bán hàng của một doanh nghiệp bán lẻ trực tuyến tại Anh trong khoảng một năm. Việc thống kê sơ bộ cho thấy dữ liệu chứa các giá trị trùng lặp, thiếu mã khách hàng và một số bất thường về số lượng, giá sản phẩm.

Về kiểu dữ liệu, phần lớn các cột đã ở định dạng phù hợp. Đáng chú ý, InvoiceDate đã được chuyển sang kiểu datetime64[ns], hỗ trợ tốt cho việc tính toán chỉ số Recency. Các cột định lượng như Quantity và UnitPrice có kiểu số (int64, float64), sẵn sàng cho bước xử lý tiếp theo.

```
## === Thông tin chung ===
```

```
## <class 'pandas.core.frame.DataFrame'>
## RangeIndex: 541909 entries, 0 to 541908
## Data columns (total 8 columns):
## #   Column          Non-Null Count  Dtype
## ---  ---
## 0   InvoiceNo       541909 non-null object
```

```
## 1 StockCode 541909 non-null object
## 2 Description 540455 non-null object
## 3 Quantity 541909 non-null int64
## 4 InvoiceDate 541909 non-null datetime64[ns]
## 5 UnitPrice 541909 non-null float64
## 6 CustomerID 406829 non-null float64
## 7 Country 541909 non-null object
## dtypes: datetime64[ns](1), float64(2), int64(1), object(4)
## memory usage: 33.1+ MB
## None
```

3.3.2. Kiểm tra giá trị thiếu và kiểu dữ liệu

Trước khi tiến hành xử lý và phân tích, cần kiểm tra tình trạng thiếu dữ liệu và kiểu dữ liệu của các trường trong tập dữ liệu

```
## === So lượng giá trị thiếu ===

## InvoiceNo 0
## StockCode 0
## Description 1454
## Quantity 0
## InvoiceDate 0
## UnitPrice 0
## CustomerID 135080
## Country 0
## dtype: int64
```

Kết quả cho thấy cột CustomerID có **135.080 giá trị bị thiếu**, chiếm khoảng **25%** tổng số dòng. Ngoài ra, cột Description cũng thiếu **1.454 giá trị**, tuy nhiên đây không phải là biến chính trong phân tích RFM nên sẽ không ảnh hưởng lớn đến kết quả. Các cột còn lại không có giá trị thiếu.

3.3.3. Phát hiện các giá trị bất thường (Quantity, UnitPrice)

Ngoài giá trị thiếu, tập dữ liệu còn chứa nhiều dòng có giá trị bất thường, không phản ánh đúng hành vi mua hàng của khách hàng.

Cụ thể, có **10.624 dòng** có $Quantity \leq 0$ và **2.517 dòng** có $UnitPrice \leq 0$. Những trường hợp này thường là các đơn hàng bị hủy, hoàn trả hoặc lỗi nhập liệu. ở giai đoạn này, nhóm **chưa loại bỏ các dòng này ngay**, mà sẽ xử lý **tại thời điểm tính chỉ số Monetary** để đảm bảo không ảnh hưởng tới các phân tích còn lại.

Một số giá trị có Quantity hoặc UnitPrice quá lớn cũng được ghi nhận, và sẽ tiếp tục được kiểm tra trong bước xử lý ngoại lệ.

3.3.4. Số lượng khách hàng và thời gian giao dịch

Sau khi kiểm tra dữ liệu, tập giao dịch còn lại chứa tổng cộng **4.372 khách hàng duy nhất** có CustomerID. Đây là cơ sở quan trọng để thực hiện phân tích theo từng cá nhân, đặc biệt là khi xây dựng mô hình RFM.

Khoảng thời gian giao dịch trải dài từ **01/12/2010 08:26:00** đến **09/12/2011 12:50:00**, tương ứng gần một năm dữ liệu. Thời gian này đủ dài để phản ánh các hành vi mua sắm theo chu kỳ, đồng thời phù hợp với mục tiêu phân cụm theo hành vi tiêu dùng.

3.3.5. Phát hiện mã bất thường trong InvoiceNo và StockCode

Trong bước khám phá dữ liệu, nhóm đã tiến hành kiểm tra kỹ lưỡng hai trường quan trọng: InvoiceNo (mã hóa đơn) và StockCode (mã sản phẩm), nhằm phát hiện các dòng không phản ánh hành vi tiêu dùng thực tế.

=== Ví dụ hóa đơn bị hủy (C...) ===

##	InvoiceNo	Quantity	CustomerID
## 141	C536379	-1	14527.0
## 154	C536383	-1	15311.0
## 235	C536391	-12	17548.0
## 236	C536391	-24	17548.0
## 237	C536391	-24	17548.0

=== Ví dụ hóa đơn chưa 'A' ===

##	InvoiceNo	Quantity	CustomerID
## 299982	A563185	1	NaN
## 299983	A563186	1	NaN
## 299984	A563187	1	NaN

Sau khi thực hiện phát hiện được có **9.288 hóa đơn bị hủy**, được đánh dấu bằng mã InvoiceNo bắt đầu với ký tự “C”. Các hóa đơn này thường đi kèm với số lượng âm trong Quantity và cần được xử lý ở bước làm sạch dữ liệu. Ngoài ra, cũng ghi nhận một số hóa đơn chứa ký tự “A”, tuy số lượng nhỏ (3 dòng) nhưng không có thông tin khách hàng (CustomerID = NaN) và cần được loại trừ để đảm bảo dữ liệu nhất quán.

Về StockCode, xuất hiện nhiều mã không đại diện cho sản phẩm cụ thể, chẳng hạn như: POST, DOT, BANK CHARGES, gift_0001_30, DCGS0076, PADS, CRUK... Đây là các dòng mang ý nghĩa phí vận chuyển, quà tặng, phụ kiện hoặc mã kỹ thuật. Những dòng này không phản ánh hành vi tiêu dùng điển hình và sẽ bị loại bỏ trước khi tính chỉ số RFM.

Nhận xét:

Qua quá trình khám phá dữ liệu, nhóm nhận thấy dữ liệu có độ phủ lớn, nhưng tồn tại nhiều vấn đề như thiếu mã khách hàng, giá trị bất thường và các mã sản phẩm không phù hợp. Các phát hiện này sẽ là cơ sở quan trọng cho bước làm sạch và xử lý dữ liệu tiếp theo, nhằm đảm bảo đầu vào chất lượng cho việc tính toán chỉ số RFM và phân cụm bằng K-Means.

3.4. Làm sạch và xử lý dữ liệu

3.4.1. Loại bỏ các giao dịch không hợp lệ

Trên cơ sở kết quả khám phá dữ liệu, nhóm đã tiến hành loại bỏ các dòng giao dịch không hợp lệ nhằm đảm bảo đầu vào sạch cho quá trình tính toán chỉ số hành vi. Hai tiêu chí chính được sử dụng để lọc dữ liệu gồm:

```
## === So luong hoa don sau khi xu ly ===
```

```
## 22061
```

Mã hóa đơn không hợp lệ: Các InvoiceNo bị hủy (bắt đầu bằng chữ “C”) hoặc không tuân thủ định dạng chuẩn gồm **6 chữ số liên tiếp** đã được loại bỏ. Đây là những hóa đơn không đại diện cho giao dịch hoàn chỉnh hoặc không thể truy xuất rõ ràng. Sau khi lọc, số hóa đơn hợp lệ còn lại là **22.061 hóa đơn duy nhất**.

```
## === So luong StockCode sau khi xu ly ===
```

```
## 4029
```

Mã sản phẩm không phù hợp: Một số StockCode không phản ánh hành vi tiêu dùng thực tế như POST, DOT, BANK CHARGES, gift_0001_30, v.v... cũng được loại bỏ. Nhóm chỉ giữ lại các mã sản phẩm thực (có 5 chữ số hoặc theo mẫu ký hiệu cụ thể), cùng với mã đặc biệt “PADS” thuộc nhóm phân tích trọng tâm. Sau bước này, còn lại **4.029 mã sản phẩm hợp lệ**.

Kết quả sau khi làm sạch cho thấy tập dữ liệu đã loại bỏ các yếu tố gây nhiễu, đồng thời đảm bảo giữ lại được phần lớn các giao dịch có thể xác định rõ khách hàng và sản phẩm. Đây là bước tiền đề quan trọng để chuẩn bị cho việc xử lý dữ liệu thiếu và tính toán chỉ số RFM ở các bước tiếp theo.

3.4.2. Xử lý dữ liệu thiếu và chuyển đổi kiểu dữ liệu

```
## === Kiểu du lieu sau khi chuyen doi ===
```

```
## InvoiceNo          object
## StockCode         object
## Description        object
## Quantity           int64
## InvoiceDate         datetime64[ns]
## UnitPrice          float64
## CustomerID         float64
## Country            object
## dtype: object
```

Trong quá trình xử lý dữ liệu, nhóm đã tiến hành loại bỏ các dòng có giá trị khuyết tại cột CustomerID. Đây là trường thông tin quan trọng để xác định người mua và phục vụ cho bước tính toán chỉ số RFM. Việc loại bỏ giúp đảm bảo chỉ các giao dịch có thể gán cho một khách hàng cụ thể được đưa vào phân tích.

Sau đó, hai trường dữ liệu chính được chuẩn hóa về kiểu dữ liệu:

- InvoiceDate được chuyển sang định dạng **thời gian (datetime64[ns])**, hỗ trợ việc tính toán Recency (khoảng thời gian mua hàng gần nhất).
- CustomerID được ép kiểu về **số nguyên (int64)**, nhằm đảm bảo tính nhất quán khi nhóm và tính toán trên từng khách hàng.

```

rows_before = df_cleaned.shape[0]
# Xóa dòng có giá trị bất thường
df_cleaned = df_cleaned[df_cleaned['Quantity'] > 0]
df_cleaned = df_cleaned[df_cleaned['UnitPrice'] > 0]
row_after = df_cleaned.shape[0]
row_deleted = rows_before - row_after

```

```
## === So dòng đã xóa ===
```

```
## 34
```

Sau khi lọc, tổng cộng **34 dòng có Quantity hoặc UnitPrice nhỏ hơn hoặc bằng 0** đã được loại bỏ. Tập dữ liệu hiện tại chỉ bao gồm các giao dịch hợp lệ, phản ánh đúng hành vi mua hàng thực tế của khách hàng, đảm bảo đầu vào chính xác cho bước tính toán RFM tiếp theo.

3.4.4. Đánh giá dữ liệu sau làm sạch

Sau quá trình làm sạch dữ liệu gồm các bước: Loại bỏ hóa đơn không hợp lệ, xử lý mã sản phẩm không phản ánh hành vi mua hàng, chuẩn hóa kiểu dữ liệu, và lọc các giao dịch có giá trị âm hoặc bằng 0 ở các cột Quantity và UnitPrice, tập dữ liệu đã được tinh gọn, đồng nhất và sẵn sàng cho quá trình phân tích RFM

Tổng quan dữ liệu sau làm sạch:

```
## So dòng còn lại: 396340
```

```
## Số khách hàng duy nhất: 4334
```

```
## Ngày giao dịch từ: 2010-12-01 đến 2011-12-09
```

```
## Tỷ lệ dữ liệu giữ lại: 73.14%
```

```
## === Thống kê mô tả sau khi drop na ===
```

	Quantity	UnitPrice	CustomerID
## count	396340.000000	396340.000000	396340.000000
## mean	13.012456	2.868200	15301.689070
## std	179.640568	4.264654	1709.957487
## min	1.000000	0.001000	12346.000000
## 25%	2.000000	1.250000	13975.000000
## 50%	6.000000	1.950000	15159.000000
## 75%	12.000000	3.750000	16803.000000
## max	80995.000000	649.500000	18287.000000


Qua bảng thống kê mô tả, có thể nhận thấy:

- **Giá trị Quantity** có độ lệch khá lớn (max = 80.995 so với mean ≈ 13), cho thấy có khả năng tồn tại một số ngoại lệ với số lượng đặt hàng rất cao.

- **UnitPrice** có giá trị trung bình thấp (≈ 2.87), nhưng vẫn xuất hiện mức giá tối đa lên đến **649.5**, cũng là dấu hiệu của giao dịch đặc biệt hoặc lỗi nhập liệu cần phân tích thêm.
- **CustomerID** phân bố đều và không có giá trị thiếu, thể hiện rằng dữ liệu khách hàng đã được làm sạch đầy đủ.

Các đặc điểm này sẽ được tiếp tục kiểm tra trong bước phát hiện ngoại lệ và chuẩn hóa, nhằm đảm bảo các cụm khách hàng được phân tích sau này phản ánh đúng bản chất hành vi tiêu dùng.

3.4.5. Trực quan hóa mối quan hệ *Quantity* – *UnitPrice* (Heatmap)



NNhóm đã kiểm tra tương quan giữa *Quantity* và *UnitPrice* hai biến cấu thành chỉ số *Monetary* trong mô hình RFM. Hệ số tương quan Pearson là **-0.02**, gần bằng 0, cho thấy hai biến gần như độc lập. Điều này xác nhận việc nhân hai biến để tính *MonetaryValue* là hợp lý, vì không có trùng lặp thông tin, đảm bảo độ chính xác cho phân tích sau đó.

Nhận xét:

- Quá trình xử lý dữ liệu đã loại bỏ các yếu tố nhiễu như giá trị thiếu, định dạng sai và giao dịch bất thường, từ đó tạo ra tập dữ liệu sạch, đầy đủ và sẵn sàng cho phân tích. Các kiểm tra thống kê cũng xác nhận rằng các biến đầu vào có tính độc lập cao và phản ánh chính xác hành vi tiêu dùng đảm bảo độ tin cậy cho các bước phân cụm tiếp theo.

3.5. Chuẩn bị dữ liệu RFM cho phân tích phân cụm

Sau khi dữ liệu đã được làm sạch và chuẩn hóa, nhóm tiến hành tính toán ba chỉ số quan trọng trong mô hình RFM – bao gồm:

- **Recency (R):** Số ngày kể từ lần mua gần nhất đến thời điểm phân tích.
- **Frequency (F):** Số lượng đơn hàng (số hóa đơn duy nhất) của mỗi khách hàng.
- **Monetary (M):** Tổng số tiền khách hàng đã chi tiêu.

3.5.1. Tạo biến SalesLineTotal cho từng giao dịch

Để chuẩn bị cho việc tính toán chỉ số **Monetary**, nhóm tiến hành tạo một biến trung gian có tên là SalesLineTotal. Biến này đại diện cho **giá trị của từng dòng giao dịch**, được tính bằng cách nhân số lượng sản phẩm (Quantity) với đơn giá (UnitPrice):

Sau khi thêm biến này, mỗi dòng dữ liệu trong bảng sẽ phản ánh chính xác giá trị thực của một giao dịch, là cơ sở để tổng hợp chi tiêu của khách hàng theo mã CustomerID.

Biến SalesLineTotal sẽ được sử dụng trong các bước tiếp theo để tính chỉ số **Monetary**, một thành phần quan trọng trong bộ đặc trưng RFM phục vụ cho việc phân cụm khách hàng.

3.5.2. Tính các chỉ số RFM theo khách hàng

Sau khi tạo biến SalesLineTotal, nhóm tiến hành tính toán ba chỉ số quan trọng trong mô hình RFM (Recency, Frequency, Monetary) theo từng khách hàng, sử dụng khóa định danh CustomerID.

Đầu tiên, nhóm sử dụng phương pháp groupby() để tổng hợp dữ liệu theo CustomerID, tính toán **MonetaryValue**, **Frequency** và ngày giao dịch cuối cùng (LastInvoiceDate) của mỗi khách hàng:

Nhóm đã tính chỉ số **Recency** bằng cách đo khoảng cách (số ngày) từ lần mua hàng gần nhất của mỗi khách hàng đến ngày giao dịch cuối cùng trong dữ liệu. Chỉ số này cho biết khách hàng đó đã mua hàng cách đây bao lâu càng nhỏ thì khách hàng càng “mới”.

Kết quả là bảng RFM hoàn chỉnh gồm ba chỉ số: Recency, Frequency và Monetary - đại diện cho hành vi tiêu dùng của 4334 khách hàng. Đây là cơ sở để tiến hành phân cụm trong các bước tiếp theo.

3.5.3. Phân tích phân phối và kiểm tra bất thường trong RFM

Sau khi tính toán được bảng chỉ số RFM, nhóm tiến hành kiểm tra phân phối và phát hiện các giá trị bất thường (outliers) trong ba chỉ số: **Recency**, **Frequency** và **Monetary**. Đây là bước quan trọng nhằm đảm bảo dữ liệu đầu vào cho phân cụm không bị méo lệch bởi những điểm ngoại lệ.

Thống kê mô tả các biến RFM:


Nhóm sử dụng hàm .describe() để xem nhanh các thông số như: giá trị trung bình, tối thiểu, tối đa và các tứ phân vị của ba biến RFM

Bảng thống kê cho thấy cả ba chỉ số RFM đều có phân phối lệch với một số giá trị lớn vượt trội:

- **Monetary** dao động mạnh từ 3.75 đến hơn **279,000**, trong khi 75% khách hàng có tổng chi tiêu dưới **1,631** đơn vị.
- **Frequency** có giá trị trung bình khoảng 4.2 nhưng giá trị lớn nhất lên tới **206** hóa đơn cho thấy sự chênh lệch rất lớn về tần suất mua hàng.
- **Recency** dao động từ **0 đến 373 ngày**, trong đó 75% khách hàng có thời gian mua hàng gần nhất cách thời điểm phân tích dưới 142 ngày.

Điều này phản ánh sự hiện diện rõ rệt của **outliers**, đặc biệt ở các chỉ số Monetary và Frequency. Do đó, bước tiếp theo là cần xử lý các giá trị bất thường để đảm bảo phân cụm chính xác và ổn định.


Phát hiện ngoại lệ bằng biểu đồ Boxplot



Biểu đồ boxplot cho thấy rõ sự tồn tại của nhiều giá trị ngoại lệ (outliers) trong cả ba chỉ số:

- **Monetary:** Có nhiều điểm vượt quá 50,000 và một số vượt 250,000 – cách xa phần lớn khách hàng.
- **Frequency:** Đa số khách hàng có số hóa đơn dưới 10, nhưng tồn tại những điểm vượt trên 200 hóa đơn.
- **Recency:** Một số khách hàng có thời gian mua hàng gần nhất cách thời điểm phân tích tới hơn 350 ngày, trong khi phần lớn có Recency dưới 150.

Phân phối trực quan của các chỉ số RFM



- **MonetaryValue** có phân phối lệch mạnh sang phải (skewed right), với nhiều điểm vượt ngưỡng 50.000 đơn vị, cho thấy sự hiện diện rõ rệt của ngoại lệ.
- **Frequency** tập trung chủ yếu ở mức dưới 5, nhưng có nhiều khách hàng mua hơn 100 lần, đây là các điểm đáng nghi ngờ.
- **Recency** phân bố không đều, với nhiều khách hàng gần thời điểm phân tích (Recency thấp), nhưng vẫn tồn tại nhóm khách mua hàng cách xa thời điểm hiện tại (Recency > 300).

Kết hợp giữa thống kê mô tả và biểu đồ trực quan, có thể thấy rằng dữ liệu RFM tồn tại **nhiều giá trị ngoại lệ**, đặc biệt ở các chỉ số Monetary và Frequency. Những giá trị này có thể làm sai lệch tâm cụm trong quá trình phân cụm bằng K-Means. Do đó, việc **xử lý outliers** là bước cần thiết trước khi chuẩn hóa và phân cụm dữ liệu.

3.5.4. Xử lý outliers trong RFM

Sau khi đã phân tích phân phối và phát hiện các giá trị bất thường trong ba chỉ số RFM, nhóm tiến hành xử lý outliers bằng phương pháp IQR đã trình bày ở phần lý thuyết.

Quy trình được thực hiện riêng biệt cho từng biến Frequency và Monetary. Mục tiêu là loại bỏ các khách hàng có hành vi tiêu dùng quá khác biệt so với phần lớn khách hàng còn lại, từ đó giúp mô hình phân cụm hoạt động ổn định và chính xác hơn.

```
# Phát hiện outlier cho 'MonetaryValue'
M_Q1 = aggregated_df["MonetaryValue"].quantile(0.25)
M_Q3 = aggregated_df["MonetaryValue"].quantile(0.75)
M_IQR = M_Q3 - M_Q1

monetary_outliers_df = aggregated_df[
    (aggregated_df["MonetaryValue"] > (M_Q3 + 1.5 * M_IQR)) |
    (aggregated_df["MonetaryValue"] < (M_Q1 - 1.5 * M_IQR))
]

# Phát hiện outlier cho 'Frequency'
F_Q1 = aggregated_df['Frequency'].quantile(0.25)
F_Q3 = aggregated_df['Frequency'].quantile(0.75)
F_IQR = F_Q3 - F_Q1

frequency_outliers_df = aggregated_df[
    (aggregated_df['Frequency'] > (F_Q3 + 1.5 * F_IQR)) |
    (aggregated_df['Frequency'] < (F_Q1 - 1.5 * F_IQR))
]
```

- Số lượng outlier trong MonetaryValue: 425 khách hàng
- Số lượng outlier trong Frequency: 278 khách hàng

Các giá trị này đều vượt quá ngưỡng IQR và được loại bỏ để đảm bảo cụm dữ liệu ổn định, không bị các điểm cực trị làm sai lệch tâm cụm trong quá trình phân cụm bằng thuật toán K-Means.

Việc loại bỏ các khách hàng này giúp cải thiện chất lượng phân cụm, tạo ra các nhóm có độ tương đồng hành vi cao hơn. Sau bước này, dữ liệu RFM đã sẵn sàng để đưa vào chuẩn hóa và phân cụm ở các bước tiếp theo.

```
# Loại bỏ outliers
non_outliers_df = aggregated_df[
    (~aggregated_df.index.isin(monetary_outliers_df.index)) &
    (~aggregated_df.index.isin(frequency_outliers_df.index))
]
```

- **Tổng số khách hàng còn lại sau khi loại outliers: 3,863** (từ tổng số ban đầu là 4,334 khách hàng)

Tỷ lệ giữ lại dữ liệu sau xử lý đạt khoảng **89.1%**, cho thấy phần lớn dữ liệu là hợp lệ và mang tính đại diện cao. Việc loại bỏ outliers giúp làm sạch dữ liệu, đảm bảo các nhóm được tạo ra trong bước phân cụm kế tiếp phản ánh đúng hành vi tiêu dùng phổ biến, tránh bị chi phối bởi thiểu số khách hàng bất thường.


3.5.5. Đánh giá dữ liệu RFM sau xử lý

Sau khi loại bỏ các giá trị ngoại lệ trong hai chỉ số **MonetaryValue** và **Frequency**, dữ liệu RFM thu được gồm **3.863 khách hàng hợp lệ**, chiếm khoảng **89% tổng số khách hàng ban đầu**. Các thống kê mô tả cho thấy phân phối của cả ba chỉ số đã trở nên ổn định hơn:

- **MonetaryValue** có giá trị trung vị khoảng 570, tối đa là 3.619.
- **Frequency** chủ yếu nằm trong khoảng 1–4 lần, ít có sự xuất hiện của giá trị quá lớn.
- **Recency** vẫn giữ được sự phân tán tự nhiên, phản ánh thời điểm mua hàng gần nhất đa dạng giữa các nhóm khách.


Nhận xét từ biểu đồ trực quan:

- **Boxplot**






Các biểu đồ hộp cho thấy hầu hết các điểm ngoại lệ lớn đã được loại bỏ. Đặc biệt là với **MonetaryValue** và **Frequency**, phần lớn dữ liệu tập trung ở nửa dưới của trục tung, thể hiện sự phân phối nghiêng phải. **Recency** vẫn có một số điểm cao hơn trung bình nhưng nằm trong giới hạn chấp nhận được.

Biểu đồ phân phối xác suất



Cả ba chỉ số RFM đều có phân phối **lệch phải**, phổ biến trong phân tích hành vi khách hàng do sự tồn tại của một số khách hàng chi tiêu rất cao hoặc mua hàng nhiều lần. Dữ liệu sau xử lý đã mượt mà và không còn nhiễu, phản ánh rõ cấu trúc của từng chỉ số.

Scatter plot 2D



Nhận xét

Monetary Value vs Frequency (After Outlier Removal)

- Biểu đồ cho thấy đa số khách hàng mua hàng ít lần nhưng giá trị giao dịch có thể rất cao. Sau khi loại bỏ ngoại lệ, dữ liệu trở nên ổn định và phản ánh đúng hành vi tiêu dùng thực tế.

Frequency vs Recency (After Outlier Removal)


- Phần lớn khách hàng mua hàng ít và đã lâu không quay lại (Recency cao). Ngược lại, khách mua thường xuyên thì có Recency thấp, tức họ mua gần đây. Mối quan hệ ngược chiều này trở nên rõ ràng hơn sau khi loại bỏ ngoại lệ.

Monetary Value vs Recency (After Outlier Removal)

- Những khách hàng chi tiêu nhiều thường không quay lại gần đây, trong khi người mua gần đây lại có giá trị giao dịch thấp. Việc loại bỏ điểm nhiễu giúp mối quan hệ này rõ ràng và dễ phân tích hơn.

Scatter plot 3D

Scatter Plot of Customer Data



Không gian ba chiều cho thấy các điểm dữ liệu có xu hướng **tập trung thành cụm** rõ ràng, cho thấy tiềm năng cao khi áp dụng các phương pháp phân cụm như K-Means. Ngoài ra, sự phân bố không quá dày đặc tại các vùng biên xác nhận rằng việc loại bỏ outlier đã giúp không gian dữ liệu trở nên rõ nét hơn.

3.6. Chuẩn hóa dữ liệu

3.6.1. Mục tiêu và lý do chuẩn hóa

Trước khi áp dụng K-Means, việc chuẩn hóa các chỉ số Recency, Frequency và MonetaryValue là cần thiết để đưa chúng về cùng thang đo. Điều này giúp đảm bảo rằng không biến nào chi phối quá trình phân cụm do có đơn vị hoặc phạm vi giá trị lớn hơn, từ đó tăng độ chính xác của mô hình.

3.6.2. Chuẩn hóa bằng Z-score (StandardScaler)

Sau khi loại bỏ các giá trị ngoại lệ, nhóm tiến hành **chuẩn hóa** các chỉ số RFM (**MonetaryValue, Frequency, Recency**) bằng phương pháp **Z-score** thông qua hàm StandardScaler trong thư viện scikit-learn. Phương pháp này đưa dữ liệu về cùng một thang đo, với giá trị trung bình xấp xỉ 0 và độ lệch chuẩn khoảng 1. Việc chuẩn hóa giúp mô hình K-Means hoạt động hiệu quả và chính xác hơn do giảm ảnh hưởng của sự chênh lệch về đơn vị giữa các biến.

Nhận xét sau chuẩn hóa:

- Trung bình (mean) của mỗi cột gần bằng 0.
- Độ lệch chuẩn (std) gần bằng 1.
- Dữ liệu đã được chuẩn hóa thành công, sẵn sàng sử dụng trong thuật toán K-Means mà không bị ảnh hưởng bởi khác biệt đơn vị đo lường giữa các biến


3.6.3. Trực quan hóa ma trận tương quan sau chuẩn hóa (Heatmap)

Sau khi chuẩn hóa dữ liệu bằng phương pháp Z-score, nhóm tiến hành trực quan hóa ma trận tương quan giữa ba biến RFM (Recency, Frequency, MonetaryValue) nhằm:

- Kiểm tra mức độ liên quan giữa các biến sau khi đã chuẩn hóa.
- Đảm bảo rằng không có mối tương quan quá cao (multicollinearity) gây ảnh hưởng tiêu cực đến mô hình phân cụm.

Nhóm sử dụng biểu đồ Heatmap để biểu diễn trực quan các hệ số tương quan. Kết quả như sau:

Heatmap tương quan giữa các biến RFM (After Scale)




Nhận xét:

- **MonetaryValue** và **Frequency** có mối tương quan dương khá cao (**0.73**), cho thấy những khách hàng mua nhiều lần thường có tổng chi tiêu cao.
- **Recency** có tương quan âm với cả **MonetaryValue** (**-0.35**) và **Frequency** (**-0.41**), điều này phản ánh rằng khách hàng mua hàng gần đây thường có tần suất và giá trị giao dịch cao hơn.
- Không có cặp biến nào có tương quan quá cao tuyệt đối ($|r| > 0.9$), do đó các biến vẫn giữ được mức độ độc lập tương đối và phù hợp để đưa vào mô hình phân cụm.

Việc trực quan hóa này giúp xác nhận rằng dữ liệu đã chuẩn bị đầy đủ và có cấu trúc phù hợp để áp dụng thuật toán **K-Means** trong bước tiếp theo.

Scatter Plot of Customer Data (After Scaling)



Nhận xét

Biểu đồ thể hiện mối quan hệ giữa ba chỉ số RFM (Recency, Frequency, Monetary Value) sau khi được chuẩn hóa cho ta thấy:

- phần lớn khách hàng tập trung ở vùng có Recency và Frequency thấp, cùng với giá trị chi tiêu (Monetary) ở mức dưới trung bình. Điều này phản ánh tập khách hàng phổ biến là những người mua hàng ít, không thường xuyên và đã không giao dịch gần đây. Một số điểm phân tán ở vùng Recency thấp – Frequency và Monetary cao cho thấy sự tồn tại của nhóm khách hàng tích cực, nhưng số lượng không nhiều. Sau khi chuẩn hóa, dữ liệu được phân bố rõ ràng và cân bằng, hỗ trợ tốt cho quá trình phân cụm tiếp theo.

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM

4.1. Phân cụm dữ liệu

Trong lĩnh vực khai phá dữ liệu, phân cụm là một kỹ thuật quan trọng thuộc học máy không giám sát, nhằm mục đích nhóm các đối tượng dữ liệu dựa trên mức độ tương đồng giữa chúng. Quá trình này giúp xác định các cấu trúc ẩn trong dữ liệu, từ đó hỗ trợ việc hiểu sâu hơn về tập dữ liệu và phát hiện các mẫu hoặc xu hướng tiềm ẩn.

Trong phần này, chúng tôi sẽ tập trung vào việc áp dụng thuật toán **K-Means** để phân cụm dữ liệu, một trong những thuật toán phổ biến và hiệu quả trong việc nhóm các đối tượng dữ liệu dựa trên sự tương đồng về đặc điểm.





4.1.1. Chọn số lượng cụm tối ưu (k) trong phân cụm K-Means

Xác định số lượng cụm (k) phù hợp là một bước quan trọng trong quá trình phân cụm K-Means.

Việc chọn đúng giá trị k giúp mô hình phân cụm hiệu quả, phản ánh đúng cấu trúc tiềm ẩn trong dữ liệu.

Dưới đây chúng tôi sử dụng bốn phương pháp để tìm số lượng cụm k tối ưu cho thuật toán bao gồm:

- Phương pháp Elbow
- Phương pháp Silhouette Score
- Calinski-Harabasz Index
- Davies-Bouldin Index



Áp dụng 4 phương pháp **Elbow**, **Silhouette Score**, **Calinski-Harabasz Index** và **Davies-Bouldin Index** từ kết quả thu được chúng tôi đưa ra kết luận sau:

Biểu đồ Elbow:

- **Điểm gấp khúc (Elbow)** rõ ràng xuất hiện tại $k = 3$ hoặc $k = 4$. Sau điểm này, mức giảm **inertia** không còn đáng kể.

Biểu đồ Silhouette Score:

- Điểm cao nhất là tại $k = 3$ (~0.46), cho thấy cấu trúc phân cụm tốt nhất ở đây.

Biểu đồ Calinski-Harabasz Index:

- Điểm cao nhất, cho thấy cấu trúc tốt nhất là $k = 3$,

Biểu đồ Davies-Bouldin Index:


- Điểm thấp nhất, chỉ ra cấu trúc phân cụm tốt nhất (vì giá trị thấp hơn là tốt hơn), là tại $k = 3$.

Kết luận Từ 4 phương pháp xác định k ở trên thì đã tìm được số k phù hợp đó chính là $k = 3$.

4.1.2. Huấn luyện mô hình phân cụm bằng K-Means

Sau khi xác định được số lượng cụm tối ưu, quá trình huấn luyện mô hình **K-Means** được tiến hành. Mục tiêu của bước này là phân chia tập dữ liệu khách hàng thành **k cụm riêng biệt**, trong đó các khách hàng trong cùng một cụm có đặc điểm tương đồng với nhau. Quá trình huấn luyện mô hình bao gồm việc khởi tạo các tâm cụm ban đầu, gán mỗi điểm dữ liệu vào cụm có tâm gần nhất, sau đó cập nhật lại vị trí của các tâm cụm dựa trên trung bình các điểm dữ liệu trong cụm. Quá trình này được lặp lại cho đến khi các tâm cụm hội tụ và không thay đổi đáng kể qua các vòng lặp.

Việc huấn luyện mô hình đóng vai trò then chốt trong việc đảm bảo các cụm khách hàng được hình thành có sự khác biệt rõ ràng và phản ánh đúng mối quan hệ giữa các đối tượng trong không gian đặc trưng. Kết quả của bước này sẽ là cơ sở để đánh giá và phân tích đặc điểm từng nhóm khách hàng trong các bước tiếp theo.



Nhận xét

Giá trị **Silhouette** trung bình là **0.45**.

-> Chất lượng phân cụm khá tốt, các cụm được phân tách tương đối rõ ràng, nhưng vẫn có một số điểm có thể nằm gần ranh giới giữa các cụm

• Chất lượng của từng cụm:

- **Cụm 0 (xanh dương):** Giá trị **Silhouette** khoảng **0.45**, bằng với giá trị trung bình. Cho thấy cụm 0 có chất lượng phân cụm tốt, các điểm trong cụm này có sự đồng nhất cao và cách xa các cụm khác.
- **Cụm 1 (xanh lá):** Giá trị **Silhouette** cũng khoảng **0.45**, tương tự như cụm 0 cụm này cũng có chất lượng phân cụm tốt, với sự phân tách rõ ràng.
- **Cụm 2 (xanh lục):** Giá trị **Silhouette** thấp hơn, khoảng **0.35**. Điều này cho thấy cụm 2 có chất lượng phân cụm kém hơn. Một số điểm trong cụm 2 có thể gần với các cụm khác hơn.

4.2. Phân tích kết quả


4.2.1. Trực quan hóa và phân tích kết quả phân cụm

Sau khi hoàn thành quá trình huấn luyện mô hình **K-Means** và xác định được các cụm khách hàng, bước tiếp theo là trực quan hóa và phân tích kết quả phân cụm. Việc trực quan hóa giúp chúng ta quan sát được sự phân bố của các cụm trong không gian đặc trưng, từ đó đánh giá mức độ tách biệt và đồng nhất của các cụm.

Kết quả phân cụm RFM trên môi trường 3D:

Trước hết, biểu đồ phân tán 3D cung cấp cái nhìn toàn cảnh về cấu trúc không gian của dữ liệu khách hàng sau khi được phân cụm.

Scatter Plot of Customer Segments



Nhận xét


- Dữ liệu đã được phân cụm khá rõ, với sự tách biệt rõ ràng giữa các nhóm. Điều này cho thấy thuật toán **K-Means** hoạt động hiệu quả sau khi chuẩn hóa và loại bỏ ngoại lệ.
- **Cụm 0 (xanh dương)** tập trung ở vùng **Monetary thấp (0-1000)** và **Frequency (0-4)**, cho thấy nhóm khách hàng có giá trị giao dịch nhỏ và tần suất thấp.
- **Cụm 1 (cam)** có **Monetary Value** từ trung bình đến cao (**1000-3500**) với **Frequency thấp**, nhóm này mua ít nhưng mỗi lần mua với giá trị cao, có thể là khách mua sỉ hoặc mua không thường xuyên.
- **Cụm 2 (xanh lá)** trải rộng ở **Frequency cao (4-10)** và **Monetary trung bình (1000-2500)**, đây là nhóm khách hàng trung thành, mua hàng gần đây và thường xuyên, rất tiềm năng.

Phân cụm cho thấy sự phân biệt rõ ràng giữa các nhóm dựa trên hành vi tiêu dùng.

Kết luận

- Kết quả phân cụm đã chia khách hàng thành 3 nhóm với đặc trưng hành vi rõ rệt.
- Trong đó, nhóm **Cluster 2** là nhóm khách hàng tiềm năng nhất với tần suất và giá trị giao dịch cao, gần đây.
- Ngược lại, nhóm **Cluster 0** có mức độ tương tác thấp, ít giá trị có thể cần chiến lược thu hút hoặc loại bỏ.

4.2.2. Phân cụm bằng t-SNE




Nhận xét

Biểu đồ trên thể hiện kết quả phân cụm khách hàng bằng **KMeans** ($k = 3$) và trực quan hóa qua kỹ thuật giảm chiều **t-SNE**. Dữ liệu sau chuẩn hóa được chiếu xuống mặt phẳng 2D, cho thấy:

- **Cụm 0 (màu đỏ)** chiếm tỷ trọng lớn nhất, phân bố rõ ràng ở các khu vực tách biệt. Đây có thể là nhóm khách hàng có tần suất mua hàng cao nhưng giá trị chỉ tiêu ở mức trung bình.
- **Cụm 1 (màu xanh dương)** tập trung ở phía trên và có phân bố khá liên tục - cho thấy đây có thể là nhóm khách hàng hoạt động đều đặn nhưng chỉ tiêu chưa cao.
- **Cụm 2 (màu xanh lá)** phân tán ở góc trên phải biểu đồ, có xu hướng cô lập, cho thấy đặc điểm hành vi khác biệt - có khả năng là nhóm khách hàng chỉ tiêu cao, mua gần đây và thường xuyên hơn (VIP).

Việc các cụm phân tách rõ ràng, không bị chồng lấn quá nhiều cho thấy mô hình **KMeans** với $k = 3$ đã phân loại khách hàng tương đối hiệu quả và có thể được dùng làm cơ sở cho các chiến lược tiếp thị cá nhân hóa.




Nhận xét

Biểu đồ thể hiện kết quả phân cụm khách hàng bằng **KMeans** với số cụm $k = 4$, trực quan hóa qua **t-SNE**. So với biểu đồ 3 cụm, việc tăng số cụm lên 4 cho thấy sự phân tách rõ nét hơn ở một số khu vực trước đây còn chồng lấn.

- **Cụm 0 (màu đỏ)** tiếp tục là nhóm khách hàng có số lượng lớn, tập trung nhiều ở phần dưới bên trái. Họ có thể là nhóm khách mua thường xuyên nhưng chi tiêu vừa phải.
- **Cụm 1 (màu xanh dương)** vẫn nằm ở phía trên trung tâm, phân bố tương đối đều. Có khả năng là nhóm khách hàng trung thành, hoạt động đều đặn.
- **Cụm 2 (màu xanh lá)** đại diện cho nhóm khách hàng nổi bật về hành vi mua sắm, thường có **Recency thấp, Frequency** và **Monetary cao**. Đây có thể là nhóm khách VIP.
- **Cụm 3 (màu tím)** là cụm mới được phân tách so với mô hình 3 cụm trước đó. Nhóm này xuất hiện ở góc dưới phải và phần rìa cụm 2, cho thấy hành vi mua hàng có sự khác biệt rõ ràng, nhiều khả năng là nhóm tiềm năng mới hoặc khách hàng quay lại gần đây.

Tóm lại, mô hình với 4 cụm phân biệt hành vi khách hàng tốt hơn, giúp doanh nghiệp dễ dàng xây dựng chiến lược chăm sóc và marketing cá nhân hóa theo từng nhóm.

4.2.3. Trực quan biểu đồ phân cụm sau khi giảm chiều bằng UMAP



Nhận xét


Biểu đồ trên sử dụng kỹ thuật **UMAP** để giảm chiều dữ liệu và trực quan hóa kết quả phân cụm khách hàng thành 3 nhóm. Các điểm dữ liệu được hiển thị trên không gian 2 chiều theo hai trục **UMAP 1** và **UMAP 2**.

Mặc dù các điểm đã được gán nhãn cụ thể theo từng cụm (**Cluster 0 - xanh dương, Cluster 1 - xanh lá, Cluster 2 - đỏ**), tuy nhiên sự phân tách giữa các cụm chưa thực sự rõ ràng, nhiều điểm dữ liệu có xu hướng chồng lấn và xen kẽ nhau. Điều này cho thấy hành vi mua hàng của các nhóm vẫn còn nhiều điểm tương đồng hoặc ranh giới giữa các cụm chưa thực sự tách biệt hoàn toàn.

Tuy vậy, UMAP vẫn mang lại giá trị trong việc giữ nguyên cấu trúc lân cận giữa các điểm, từ đó phản ánh độ liên kết và mật độ phân bố khách hàng trong toàn bộ tập dữ liệu. Kết quả này

có thể giúp doanh nghiệp cân nhắc các nhóm khách hàng cận biên và xây dựng các chính sách tiếp cận linh hoạt hơn.

4.2.4. Trực quan kết quả phân cụm các nhóm khách hàng bằng biểu đồ Violin




Nhận xét

Biểu đồ **Violin** trên minh họa phân bố giá trị chỉ tiêu (**Monetary Value**) của khách hàng trong từng cụm đã phân nhóm.

- **Cluster 0 (màu xanh dương)** có mức chỉ tiêu trung bình ở mức trung bình - phân bố tập trung quanh mốc **500** đến **1.000**. Đây có thể là nhóm khách hàng phổ thông, chi tiêu ổn định.
- **Cluster 1 (màu xanh lá)** là nhóm có giá trị chỉ tiêu thấp nhất và tập trung chủ yếu ở dưới **500**, cho thấy đây là nhóm khách hàng ít giá trị hoặc ít tương tác.
- **Cluster 2 (màu đỏ)** có mức chỉ tiêu trung bình cao nhất và phân bố rộng, cho thấy đây là nhóm khách hàng có giá trị cao. Phần lớn khách trong nhóm này chi tiêu từ khoảng **1.500** đến **3.000**, với nhiều điểm dữ liệu tập trung ở mức cao.

Từ biểu đồ, có thể thấy việc phân cụm đã phản ánh tương đối rõ nét về mức chi tiêu giữa các nhóm khách hàng, đặc biệt là sự nổi bật của cụm khách hàng tiềm năng (**Cluster 2**), từ đó hỗ trợ đề xuất các chiến lược giữ chân, chăm sóc phù hợp.




Nhận xét

Biểu đồ thể hiện sự phân bố tần suất mua hàng (**Frequency**) của từng cụm khách hàng sau khi phân nhóm.

- **Cluster 0 (màu xanh dương)** có tần suất mua hàng ở mức trung bình - phần lớn dao động từ 1 đến 3 lần mua. Đây là nhóm khách hàng phổ thông, tương tác ở mức vừa phải.
- **Cluster 1 (màu xanh lá)** là nhóm có tần suất thấp nhất, tập trung dày đặc quanh mức 1. Điều này cho thấy đây là nhóm khách hàng kém tương tác hoặc chỉ mua một lần, cần được chú ý trong các chiến lược kích hoạt lại.
- **Cluster 2 (màu đỏ)** tiếp tục là nhóm nổi bật nhất với tần suất mua hàng cao, đa phần khách hàng trong nhóm này có **Frequency** từ 4 đến 10, với phân bố rộng và đậm đặc. Đây là nhóm khách hàng hoạt động thường xuyên, có thể được xếp vào nhóm trung thành hoặc thân thiết.

Biểu đồ này cho thấy sự khác biệt rõ nét về hành vi mua hàng giữa các cụm, đặc biệt là **cụm 2** - nhóm khách hàng giá trị cao cả về số lần mua lẫn chi tiêu.



Nhận xét

Biểu đồ cho thấy sự khác biệt rõ rệt về thời gian mua hàng gần nhất (**Recency**) giữa các cụm khách hàng:

- **Cluster 0 (màu xanh dương)** có **Recency** ở mức trung bình - phần lớn khách mua hàng cách đây khoảng 30–80 ngày, thuộc nhóm khách hàng tiềm năng có thể tái kích hoạt.
- **Cluster 1 (màu xanh lá)** có **Recency** cao nhất - nhiều khách hàng mua hàng cách đây hơn 200 ngày, cho thấy đây là nhóm khách hàng đã lâu không quay lại và có nguy cơ rời bỏ cao.

Việc phân tích **Recency** giúp doanh nghiệp xác định được nhóm khách nào cần tập trung vào chiến lược duy trì (**Cluster 2**), nhóm cần khuyến khích mua lại (**Cluster 0**) và nhóm cần kích hoạt lại hoặc xem xét loại trừ (**Cluster 1**).


4.2.5. Phân loại các nhóm ngoại lai theo 2 chỉ số (Monetary) và (Frequency)

Nhóm tiến hành xác định các điểm ngoại lệ (outliers) theo hai tiêu chí là Monetary và Frequency. Sau đó, các outlier được chia thành ba nhóm riêng biệt:

- Những khách hàng chỉ là outlier theo **Monetary**.
- Những khách hàng chỉ là outlier theo **Frequency**.
- Những khách hàng đồng thời là outlier ở cả hai tiêu chí trên.

4.2.6. Trực quan kết quả phân cụm các nhóm khách hàng ngoại lai

Biểu đồ phân bố chỉ tiêu (Monetary Value) của các nhóm khách hàng ngoại lai




Nhận xét

Biểu đồ trên thể hiện sự khác biệt về giá trị chỉ tiêu trong ba nhóm khách hàng được xác định là ngoại lai theo các chỉ số RFM:

- **Cluster -1** (ngoại lai theo **Monetary**): Đây là nhóm có giá trị chỉ tiêu rất cao, nhiều khách hàng có **Monetary Value** vượt xa trung bình chung. Mặc dù số lượng không nhiều, nhưng những khách này có thể là các đơn hàng bất thường, hoặc những khách hàng doanh nghiệp, cần được kiểm tra kỹ lưỡng để đánh giá tính hợp lệ trước khi ra quyết định marketing.
- **Cluster -2** (ngoại lai theo **Frequency**): Nhóm này có chỉ tiêu thấp nhất trong cả ba nhóm ngoại lai, tập trung quanh ngưỡng dưới **5**. Dù có tần suất mua cao, nhưng giá trị đơn hàng nhỏ dẫn tới tổng chỉ tiêu thấp. Có thể là nhóm khách hàng nhỏ nhưng mua nhiều lần, hoặc hành vi “spam đơn hàng” cần được kiểm chứng.
- **Cluster -3** (ngoại lai theo cả **Monetary** và **Frequency**): Đây là nhóm đặc biệt với giá trị chỉ tiêu rất cao và cũng có tần suất mua hàng lớn. Phân bố trải rộng, với một số khách hàng vượt xa mốc **100,000** đơn vị chỉ tiêu. Nhóm này có thể bao gồm các khách hàng cực kỳ giá trị (VIP) hoặc các điểm dữ liệu bất thường cần được kiểm tra để loại bỏ nhiễu.

Biểu đồ giúp nhận diện rõ ràng mức độ ảnh hưởng của từng nhóm ngoại lai, từ đó hỗ trợ quyết định **loại trừ** khỏi mô hình phân cụm chính hoặc xây dựng chiến lược chăm sóc chuyên biệt cho các khách hàng đặc biệt này.

Biểu đồ phân bố chi tiêu (Frequency) của các nhóm khách hàng ngoại lai




Nhận xét

Biểu đồ thể hiện sự phân bố số lần mua hàng (**Frequency**) trong ba nhóm khách hàng được xác định là ngoại lai theo các chỉ số RFM:

- **Cluster -1** (ngoại lai theo **Monetary**): Nhóm này có tần suất mua hàng thấp, chủ yếu dưới 10 lượt mua. Mặc dù chi tiêu cao, nhưng số lần mua không nhiều, phản ánh những khách hàng có giá trị đơn hàng lớn nhưng không mua thường xuyên.
- **Cluster -2** (ngoại lai theo **Frequency**): Đây là nhóm có tần suất mua hàng cao bất thường, với một số cá nhân vượt quá 40 lần mua cho thấy hành vi mua lặp lại liên tục, có thể là khách hàng tổ chức hoặc người có hành vi “spam” đơn hàng. Tuy nhiên, phần lớn khách vẫn dao động trong khoảng từ 10–20 lần mua.
- **Cluster -3** (ngoại lai theo cả **Monetary** và **Frequency**): Là nhóm có phân bố rộng và tần suất rất cao, nhiều điểm dữ liệu vượt mốc 100. Đây có thể là khách hàng doanh nghiệp lớn, khách hàng chiến lược hoặc cũng có thể bao gồm các điểm dữ liệu bất thường cần xem xét lại kỹ lưỡng về tính hợp lệ.

Biểu đồ giúp nhận diện rõ hơn mức độ “lặp lại” trong hành vi mua hàng của các nhóm ngoại lai và hỗ trợ doanh nghiệp xác định đâu là nhóm nên duy trì, nên kiểm tra hoặc nên loại trừ trong chiến lược phân khúc và chăm sóc.

Biểu đồ phân bố chi tiêu (Recency) của các nhóm khách hàng ngoại lai



Nhận xét

Biểu đồ trên minh họa sự khác biệt về thời gian mua hàng gần nhất (**Recency**) giữa ba nhóm khách hàng được xác định là ngoại lai theo các chỉ số RFM:

- **Cluster -1** (ngoại lai theo **Monetary**): Nhóm này có **Recency** phân bố tương đối rộng, trải dài từ vài ngày đến hơn **300** ngày. Tuy nhiên, phần lớn khách hàng trong nhóm này có **Recency thấp**, nghĩa là họ vẫn tương tác tương đối gần đây. Đây có thể là nhóm khách chi tiêu lớn, vẫn còn hoạt động, cần được ưu tiên chăm sóc cá nhân hóa.
- **Cluster -2** (ngoại lai theo **Frequency**): Dù có tần suất mua cao, nhưng nhóm này cũng có **Recency thấp** nghĩa là phần lớn khách hàng quay lại trong vòng **30 ngày** gần nhất. Hành vi này thể hiện nhóm khách năng động, có thể mua lặp lại với giá trị thấp, thích hợp cho các chương trình ưu đãi theo lần mua.
- **Cluster -3** (ngoại lai theo cả **Monetary** và **Frequency**): Đây là nhóm có **Recency thấp nhất**, hầu hết khách hàng mua hàng rất gần đây. Điều này càng khẳng định tính “năng động” và “giá trị cao” của nhóm này. Tuy nhiên, cũng có một số điểm dữ liệu có **Recency cao bất thường** nên cần kiểm tra lại để xác minh có phải ngoại lệ thực sự.

Việc phân tích **Recency** cho nhóm khách hàng ngoại lai giúp doanh nghiệp đánh giá khả năng quay lại gần đây và từ đó xác định nhóm nào nên được duy trì, kích thích tiếp tục mua hoặc đánh giá lại trước khi đưa vào phân tích chiến lược.

4.3. Đề xuất chiến lược phù hợp cho các nhóm khách hàng

4.3.1. Đề xuất chiến lược cho các nhóm chính

Dựa trên phân tích trực quan ba chỉ số RFM, ba cụm khách hàng chính thể hiện những đặc điểm hành vi tiêu dùng rõ rệt, từ đó làm cơ sở cho việc đề xuất chiến lược tiếp cận phù hợp như sau:

- **Cluster 0:** Nhóm khách hàng tiềm năng, cần được nuôi dưỡng.
 - **Chiến lược đề xuất:**
 - * Khuyến khích mua lại bằng mã giảm giá, ưu đãi combo, hoặc chương trình “mua 3 tặng 1”.
 - * Sử dụng email remarketing nhắc nhở sản phẩm, gợi ý sản phẩm mới.
 - * Tặng tương tác bằng cách mời tham gia mini game, khảo sát trúng thưởng hoặc chương trình giới thiệu bạn bè.
- **Cluster 1:** Nhóm khách hàng có khả năng rời bỏ hoặc ít giá trị.
 - **Chiến lược đề xuất:**
 - * Triển khai chiến dịch kích hoạt lại (re-engagement) qua email hoặc tin nhắn cá nhân hoá.
 - * Đề xuất các sản phẩm giá thấp, rủi ro mua thấp để khuyến khích hành vi mua lại.
 - * Nếu không có phản hồi trong thời gian dài, có thể cân nhắc chuyển sang nhóm bị động, ưu tiên tập trung nguồn lực cho nhóm khách hàng tiềm năng hơn.
- **Cluster 2:** Nhóm khách hàng giá trị cao, trung thành.

– **Chiến lược đề xuất:**

- * Duy trì mối quan hệ bền vững bằng các chương trình khách hàng thân thiết hoặc hạng thành viên cao cấp.
- * Gửi ưu đãi cá nhân hóa dựa trên lịch sử mua hàng và hành vi trước đó.
- * Tạo cảm giác được trân trọng bằng các hoạt động như tri ân theo quý, tặng quà sinh nhật, hoặc ưu tiên hỗ trợ.

4.3.2. Đề xuất chiến lược cho các nhóm ngoại lai

Dựa trên phân tích trực quan các chỉ số RFM, ba nhóm khách hàng ngoại lai (-1, -2, -3) thể hiện những hành vi tiêu dùng khác biệt rõ rệt so với các cụm khách hàng chính. Những nhóm này cần được đánh giá riêng và xây dựng chiến lược chăm sóc hoặc xử lý phù hợp nhằm tận dụng tối đa giá trị hoặc hạn chế ảnh hưởng bất thường đến phân tích tổng thể.

• **Cluster -1: Ngoại lai theo Monetary**

– **Chiến lược đề xuất:**

- * Xác minh tính hợp lệ của các đơn hàng để loại trừ giao dịch bất thường.
- * Nếu là khách thật: Phân loại thành nhóm khách giá trị lớn một lần, gợi ý mua tiếp sản phẩm tương tự với ưu đãi cao cấp.
- * Ưu tiên xây dựng mối quan hệ dài hạn, khuyến khích mua lặp lại với chính sách chăm sóc chuyên biệt.

• **Cluster -2: Ngoại lai theo Frequency**

– **Chiến lược đề xuất:**

- * Tăng giá trị đơn hàng trung bình bằng combo ưu đãi, mã giảm giá theo mốc chi tiêu.
- * Nếu là hành vi hợp lệ: Nuôi dưỡng nhóm khách hàng nhỏ thường xuyên bằng tích điểm.
- * Nếu nghi ngờ “spam” đơn hàng: cần theo dõi và lọc tài khoản không hợp lệ.

• **Cluster -3: Ngoại lai theo cả Monetary và Frequency**

– **Chiến lược đề xuất:**

- * Phân tách và kiểm tra dữ liệu kỹ lưỡng: Nhóm này có thể vừa là khách VIP, vừa là giao dịch bất thường.
- * Nếu xác định là khách chiến lược: Cần thiết lập gói chăm sóc riêng, hotline riêng, hợp đồng định kỳ.
- * Nếu khách hàng thuộc nhóm doanh nghiệp hoặc mua hàng với số lượng lớn, có thể xem xét áp dụng hình thức bán sỉ hoặc ký kết hợp đồng dài hạn.

Kết luận

Việc xử lý và phân tích riêng nhóm khách hàng ngoại lai giúp nâng cao chất lượng phân cụm, đồng thời hỗ trợ doanh nghiệp xây dựng các chương trình chăm sóc riêng biệt, phù hợp với hành vi tiêu dùng bất thường nhưng tiềm năng cao.

4.4. Gán nhãn và trình bày kết quả phân cụm khách hàng

4.4.1 Tiến hành gán nhãn chiến lược cho các cụm

Sau khi phân cụm, nhóm tiến hành gán nhãn cho từng nhóm khách hàng dựa trên đặc điểm hành vi mua sắm và mục tiêu chiến lược. Cụ thể:

- **Cụm 0 – “NUR”**: Khách hàng tiềm năng, cần được chăm sóc để gia tăng giá trị lâu dài.
- **Cụm 1 – “RE”**: Khách hàng có nguy cơ rời bỏ, cần được tương tác lại để giữ chân.
- **Cụm 2 – “REW”**: Khách hàng trung thành, nên được tri ân và duy trì mối quan hệ bền vững.
- **Cụm -3 – “PAM”**: Khách VIP, cần được ưu ái với các dịch vụ và chính sách đặc biệt.
- **Cụm -2 – “UPS”**: Khách hàng mới, có thể được đề xuất thêm sản phẩm hoặc dịch vụ.
- **Cụm -1 – “DEL”**: Nhóm khách trung thành nhưng có giá trị chi tiêu thấp, cần tạo trải nghiệm xuất sắc để nâng cao sự hài lòng.

Việc gán nhãn giúp định hướng rõ chiến lược tiếp cận và chăm sóc phù hợp cho từng nhóm khách hàng sau phân cụm.

4.4.2 Tạo bảng dữ liệu phân cụm đầy đủ

Sau khi đã thực hiện phân cụm và gán nhãn chiến lược cho cả nhóm khách hàng chính và các nhóm ngoại lệ, nhóm tiến hành hợp nhất toàn bộ dữ liệu thành một bảng duy nhất, gọi là `full_clustering_df`. Bảng này bao gồm tất cả khách hàng với nhãn phân cụm đã được ánh xạ thành tên cụ thể tương ứng với chiến lược tiếp cận.


Kết quả phân bố khách hàng theo từng nhãn cụm như sau:

4.4.3 Ánh xạ tên chiến lược cho từng cụm khách hàng

Nhóm chúng tôi tiến hành ánh xạ nhãn chiến lược (ClusterLabel) cho từng cụm khách hàng đã phân nhóm, giúp dễ dàng theo dõi và trình bày kết quả.

4.4.4 Trực quan hóa phân bố khách hàng và giá trị trung bình theo cụm

Biểu đồ kết hợp dưới đây minh họa số lượng khách hàng theo từng cụm (**Barplot**) và giá trị trung bình các chỉ số **Recency**, **Frequency**, **Monetary** (**đã chuẩn hóa**) trên cùng một biểu đồ (**lineplot**). Qua đó giúp đánh giá được quy mô cũng như đặc điểm nổi bật của từng nhóm khách hàng.



Nhận xét

Biểu đồ thể hiện rõ sự khác biệt về quy mô và đặc điểm hành vi giữa các nhóm khách hàng:

- **NURTURE** là nhóm lớn nhất với hơn **2000 khách hàng**. Tuy nhiên, họ có giá trị chi tiêu (**Monetary**) và tần suất mua hàng (**Frequency**) ở mức thấp, dù **Recency** tương đối gần. Đây là nhóm tiềm năng, cần được nuôi dưỡng để gia tăng giá trị.
- **RE-ENGAGE** có số lượng khách trung bình nhưng lại có **Recency** rất cao, cho thấy họ đã lâu không mua hàng. Đồng thời, cả **Frequency** và **Monetary** đều thấp. Đây là nhóm có nguy cơ rời bỏ cao, cần các chiến dịch kích hoạt lại.
- **REWARD** là nhóm có chỉ số **Frequency** và **Monetary** cao nhất, và **Recency** thấp. Đây là nhóm khách trung thành và mang lại giá trị lớn, cần được duy trì và tri ân.
- **PAMPER** nổi bật với **Monetary** trung bình vượt trội dù tần suất không quá cao. Đây là nhóm VIP cần được cá nhân hóa trải nghiệm và chăm sóc đặc biệt.
- **DELIGHT** có chỉ số trung bình khá tốt, đặc biệt là **Recency** thấp và **Frequency** ổn định. Đây là nhóm khách hàng trung thành tiềm năng, nên tập trung vào duy trì lòng trung thành qua ưu đãi mềm.
- **UPSELL** là nhóm nhỏ nhất, nhưng có **Recency** rất thấp, **Frequency** ở mức trung bình. Đây là khách mới tiềm năng, nên tận dụng thời điểm này để giới thiệu thêm sản phẩm (**cross-sell, upsell**).

CHƯƠNG 5: KẾT LUẬN VÀ KIẾN NGHỊ

5.1. Kết luận

Nghiên cứu đã ứng dụng thành công mô hình RFM kết hợp với thuật toán K-means để phân nhóm khách hàng, thu được 3 cụm chính gồm:

- **REWARD** (khách hàng trung thành)
- **RE-ENGAGE** (nguy cơ rời bỏ)
- **NURTURE** (tiềm năng)

Bên cạnh đó, phân tích thêm các ngoại lệ (**outliers**) đã xác định thêm 3 nhóm: **VIP (PAMPER)**, **mới (UPSELL)** và **đang suy giảm (DELIGHT)**.

Mô hình đạt hệ số **Silhouette ~0.45**, cho thấy phân cụm có độ phân tách tương đối rõ, hỗ trợ hiệu quả cho việc xây dựng chiến lược tiếp thị cá nhân hóa.

Tuy nhiên, nghiên cứu vẫn còn hạn chế như:

- Dữ liệu chỉ trong một năm, chưa phản ánh yếu tố mùa vụ
- Chưa tích hợp nhân khẩu học, tâm lý khách hàng
- Chưa so sánh với các mô hình phân cụm khác

5.2. Kiến nghị

Để nâng cao hiệu quả và tính ứng dụng, nghiên cứu có thể mở rộng theo hướng:

- Áp dụng **RFM động** để theo dõi hành vi theo thời gian.
- Kết hợp với thuật toán khác như DBSCAN hoặc Hierarchical Clustering.
- Bổ sung dữ liệu nhân khẩu học để phân tích sâu hơn.
- Tích hợp dự đoán Customer Lifetime Value (LTV) để đánh giá tiềm năng khách hàng dài hạn.

Mô hình RFM-Kmeans là nền tảng hiệu quả để doanh nghiệp hiểu khách hàng, tối ưu hóa nguồn lực và xây dựng chiến lược chăm sóc phù hợp theo từng phân khúc.

TÀI LIỆU THAM KHẢO

- [1] “Hành vi khách hàng là gì? Các bước phân tích hành vi khách hàng”. Available at: <https://www.pace.edu.vn/tin-kho-tri-thuc/hanh-vi-khach-hang>
- [2] “Phân khúc khách hàng là gì? Chìa khoá xây dựng chiến lược marketing”. Available at: <https://base.vn/blog/phan-khuc-khach-hang/>
- [3] “Khoa học dữ liệu”. Available at: <https://phamdinhhkhanh.github.io/2019/11/08/RFMModel.html#i-m%C3%B4-h%C3%A0nh-rfm-recency---frequency---monetary-model>
- [4] “Getting the Most out of All Your Customers”. Available at: <https://hbr.org/2004/07/getting-the-most-out-of-all-your-customers>
- [5] “RFM Segmentation”, *Optimize*. Available at: <https://www.optimove.com/resources/learning-center/rfm-segmentation>
- [6] “The Value of Keeping the Right Customers”. Available at: <https://hbr.org/2014/10/the-value-of-keeping-the-right-customers>
- [7] “Phân tích RFM là gì? Phân loại khách hàng theo mô hình RFM”. Available at: <https://bizfly.vn/techblog/phan-tich-rfm-la-gi-phan-loai-khach-hang-theo-mo-hinh-rfm.html>
- [8] “Feature scaling”, *Wikipedia*. Tháng Tám 2024. Available at: https://en.wikipedia.org/w/index.php?title=Feature_scaling&oldid=1241939671
- [9] “Web Scraping là gì? [Hướng dẫn từng bước đầy đủ]”. Tháng Mười-Một 2020. Available at: <https://careerfoundry.com/en/blog/data-analytics/web-scraping-guide/>
- [10] “Detecting and Treating Outliers | Treating the odd one out!” Available at: <https://www.analyticsvidhya.com/blog/2021/05/detecting-and-treating-outliers-treating-the-odd-one-out/#h-detecting-outliers-using-boxplot>
- [11] N. N. Son, “K means là gì? Các công bố khoa học về K means”, *Scholar Hub*. Available at: [https://scholarhub.vn/topic/k means](https://scholarhub.vn/topic/k%20means)
- [12] N. Sharma, “K-Means Clustering Explained”, *neptune.ai*. Tháng Bảy 2022. Truy cập: 3 Tháng Tư 2025. [Online]. Available at: <https://neptune.ai/blog/k-means-clustering>
- [13] admin, “K-Means Clustering: Ưu nhược điểm và hướng áp dụng”, *Alcandy*. Tháng Tám 2024. Available at: <https://aicandy.vn/k-means-clustering-uu-nhuoc-diem-va-huong-ap-dung/>
- [14] N. Sharma, “K-Means Clustering Explained”, *neptune.ai*. Tháng Bảy 2022. Available at: <https://neptune.ai/blog/k-means-clustering>
- [15] T. Kaur, “Determining the Optimal Number of Clusters Using the Elbow Method: How, When, Where, What, and Why”, *Medium*. Tháng Năm 2025. Available at: <https://medium.com/@tarangds/determining-the-optimal-number-of-clusters-using-the-elbow-method-how-when-where-what-and-why-cd1e94b82c1e>
- [16] “Silhouette (clustering)”, *Wikipedia*. Tháng Tư 2025. Available at: [https://en.wikipedia.org/w/index.php?title=Silhouette_\(clustering\)&oldid=1286028367](https://en.wikipedia.org/w/index.php?title=Silhouette_(clustering)&oldid=1286028367)
- [17] “Calinski–Harabasz index”, *Wikipedia*. Tháng Năm 2025. Available at: https://en.wikipedia.org/w/index.php?title=Calinski%E2%80%93Harabasz_index&oldid=1291605901
- [18] “Davies–Bouldin Index | GeeksforGeeks”. Available at: <https://www.geeksforgeeks.org/davies-bouldin-index/>
- [19] “Giảm chiều dữ liệu”, *Wikipedia tiếng Việt*. Tháng Mười 2023. Available at: https://vi.wikipedia.org/w/index.php?title=Gi%E1%BA%A3m_chi%E1%BB%81u_d%E1%BB%AF_li%E1%BB%87u&oldid=70805513

- [20] “PCA vs. t-SNE: Unveiling the Best Dimensionality Reduction Technique for Your Data”, *DEV Community*. Tháng Chín 2024. Available at: <https://dev.to/sreeni5018/pca-vs-t-sne-unveiling-the-best-dimensionality-reduction-technique-for-your-data-ekc>
- [21] “UMAP: Phép xấp xỉ và phép chiếu đa tạp thống nhất để giảm kích thước — tài liệu umap 0.5.8”. Available at: <https://umap-learn.readthedocs.io/en/latest/>